Università degli Studi di Roma Tor Vergata



Facoltà di Ingegneria

Corso di Metriche e Modelli per Internet

Progetto A

Professore:
Salvatore Tucci
Emiliano Casalicchio

Studenti:
Ibrahim Khalili
Simone Notargiacomo
Lorenzo Tavernese

Anno Accademico 2007-2008

Indice

1	Inti	oduzione			3
	1.1	Requisiti del Progetto	 		4
	1.2	Approccio Adottato	 		6
2	Car	atterizzazione del Workload			7
	2.1	Partizionamento del Carico	 	•	8
3	Sim	ulazione			12
	3.1	CSIM	 		12
	3.2	Rappresentazione del workload	 		14
	3.3	Rappresentazione delle risorse	 		16
	3.4	Dimensionamento del Sistema	 		19
	3.5	Transiente	 		21
	3.6	Struttura della simulazione	 		24
		3.6.1 Webclient	 		25
		3.6.2 Il processo principale	 		28
	3.7	Presentazione dei risultati	 		29
		3.7.1 Risultati Random	 		30
		3.7.2 Risultati Round Robin	 		31
		3.7.3 Risultati Least Loaded	 		33
		3.7.4 Risultati Proxy	 		35
		3.7.5 Risultati Link Addizionale	 		35

INDICE

4	Mo	lello Analitico	40
	4.1	Presentazione dei risultati	42
		4.1.1 Risultati standard	42
		4.1.2 Risultati proxy	44
		4.1.3 Risultati Link Addizionale	46
5	Con	clusioni	48
6	App	endice	50
	6.1	common.h	50
	6.2	cluster.c	52
	6.3	gaussiana_inversa.c	57
	6.4	service.c	60
	6.5	client.c	63
	6.6	transient.c	68
	6.7	main.c	74
	6.8	analytical.c	88

Capitolo 1

Introduzione

Il lavoro svolto per l'esame di Metriche e Modelli di Internet ha posto l'interesse nell' analisi del comportamento di un sistema web al variare di alcune sue componenti. Nello specifico sono state condotte due tipi di analisi, la prima da un punto di vista simulativo mentre la seconda da un punto di vista analitico. Entrambe fanno riferimento ad una rappresentazione matematica del sistema reale(modello) denominata rete di code(QN, Queueing Network). Una QN tiene conto della contesa per le risorse del sistema e delle code che si generano in attesa del servizio. La soluzione analitica consente di risolvere mediante l'uso di formule e algoritmi una rete di code, ottenendo in questo modo i valori prestazionali desiderati. Tali valori possono altresì essere ottenuti emulando il comportamento del sistema attraverso una simulazione. La simulazione è realizzata mediante un programma in grado di mimare il funzionamento del sistema attraverso flussi di transazioni tra le varie risorse. I valori di performance sono ricavati dalle statistiche collezionate dal programma per ogni coda relativa a tali risorse. Per poter generare un modello di performance è necessario innanzitutto stilare un modello che rappresenti il workload, che nel caso specifico, è stato generato a partire da diverse distribuzioni rappresentanti più valori, come ad esempio il numero di richieste per sessione o la dimensione della pagina html richiesta. Per rendere più chiara l'idea al lettore, si presentano di seguito i requisiti del progetto.

1.1 Requisiti del Progetto

Si consideri il cluster di Server Web in figura 1.1. Il sistema è composto da un Web Switch che riceve le richieste dagli utenti e le distribuisce ad un set di N Server Web. Il Web Switch è connesso alla rete internet mediante il link L1. I Web Server e il Web Switch sono tra di loro connessi mediante la LAN L2. Ogni server è caratterizzato da una CPU, da uno o più dischi ed una scheda di rete (Iw2). La CPU dei server ha un tasso di servizio pari a 150 richieste al secondo (indipendentemente dal tipo di richieste). Il disco ha le seguenti caratteristiche: Seek Time 8.5ms, Controller Time 0.2ms, Rotational Speed 7200 RPM, transfer rate 100MB/sec, block size 2048 byte. Il Web Switch è caratterizzato da una CPU e da due scheda di rete (Is1 e Is2), una che lo connette alla rete L1 ed una che lo connette alla rete L2. La rete L2 è una rete Ethernet 1000Mbit/sec e sia i Web Server che il Web Switch sono ad essa connessi mediante delle schede di rete con un transfer rate di 1000Mbit/sec.

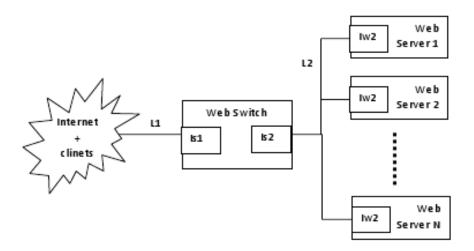


Figura 1.1: Schema

Si suppone che il carico del sistema è caratterizzato come segue:

Richieste	Gaussiana Inversa	$X > 0; \mu = 3.86;$
per Sessione		$\lambda = 9.46$
User Think Time	Pareto	$X \ge k; \alpha = 1.4; k = 1$
Num. Oggetti	Pareto	$X \ge k; \alpha = 1.33; k = 2$
per Richiesta		
Dim. Pag. HTML	LogNormale-Pareto	$\mu = 7.63; \sigma = 1.001$
		$X \ge k; \alpha = 1; k = 10240(byte)$
Embedded Objects	LogNormale	$X > 0; \mu = 8.215; \sigma = 1.46$

Tabella 1.1: specifiche

Si chiede agli studenti di studiare il comportamento del sistema utilizzando un modello di simulazione e, fatta l'opportuna caratterizzazione del carico, mediante la risoluzione di un modello analitico. Nello specifico si chiede di:

- Dimensionare opportunamente il sistema per far si che sia in grado di sopportare un carico di 150 utenti al secondo con un utilizzazione massima della risorsa collo di bottiglia compresa tra il 65 ed il 70%.
- Studiare le prestazioni del sistema al variare delle politiche di selezione dei server (ROUND ROBIN, RANDOM, LEAST LOADED)
- Valutare che impatto ha sulle prestazioni del sistema l'introduzione di
 - 1. una scheda di rete addizionale per i web server (per la gestione separata delle richieste in ingresso ed in uscita)
 - 2. un link in uscita, dimensionato opportunamente, per lo smistamento delle risposte (Vedi fig. 1.2)
- Valutare che impatto ha, sulle prestazioni del sistema, l'introduzione di un proxy server che offra un cache hit rate del 40%.

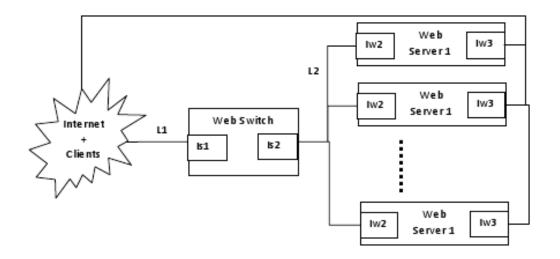


Figura 1.2: Schema

1.2 Approccio Adottato

Si presenta di seguito un breve sunto dei passi che hanno consentito di realizzare il progetto (NON MI PIACE PER NIENTE, DA CORREGGERE), e che verranno affrontati nei capitoli successivi.

- 1. Caratterizzazione del workload raggruppando i documenti in cluster in base alle loro dimensioni;
- 2. Scelta delle risorse da modellare come centri di servizio
- 3. Sviluppo della simulazione ed esecuzione di un set di simulazione per la stima dei parametri da modellare;
- 4. Studio del transiente
- 5. Esclusione del transiente dalla simulazione
- 6. Sviluppo ed esecuzione del modello analitico

Capitolo 2

Caratterizzazione del Workload

Il workload del sistema può essere visto come un insieme di tutti gli input che questo riceve durante un dato periodo di tempo. Un modello di workload è pertanto una rappresentazione che imita il comportamento del carico reale e risulta utile in quanto permette di modificare in modo semplice i parametri per osservare la risposta del sistema. Il carico di un sistema Web può essere caratterizzato a diversi livelli di astrazione. Il livello più elevato è detto di business, e si rivela utile per descrivere il carico in termini di peculiarità delle applicazioni principali; immediatamente sotto vi è il livello di caratterizzazione funzionale, il quale descrive i programmi, le richieste o le applicazioni che compongono il carico. L'ultimo livello di dettaglio, detto orientato alle risorse, consente di caratterizzare il consumo delle risorse del sistema dovuto al workload e poichè i due livelli più alti non consentono di catturare queste informazioni in modo quantitativo, si è adottato proprio quest'ultimo livello di dettaglio, in quanto è stato modellato il consumo delle risorse in termini di domanda di servizio e di intensità di carico (misurata in richieste HTTP/sec sottoposte al web server).

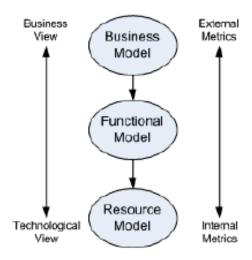


Figura 2.1: Schema

Questa metrica è ben diversa dal numero di utenti che accedono in media al sistema ogni secondo, o al numero di richieste di pagine HTML sottoposte in media al sistema; in quest'ultimo caso, infatti, non si terrebbe conto dei numerosi oggetti inclusi in una pagina HTML. Non essendo in possesso di un carico reale (ad esempio un log di sistema), non è stato possibile effettuare un'analisi del fattore di burstiness poichè non si conoscevano il numero medio di richieste HTTP ricevute dal sistema in un determinato intervallo di tempo, nè tanto meno effettuare un'analisi analitica. Di conseguenza, la prima operazione eseguita è stata quella di effettuare un partizionamento dei documenti sulla base dei valori presentati in tabella (tabella requisiti del progetto).

2.1 Partizionamento del Carico

I carichi reali possono presentare componenti molto eterogenee tra loro, in particolar modo per quel che riguarda la loro utilizzazione delle risorse del sistema; spesso la rappresentazione di un carico mediante una sola classe manca di accuratezza in questo senso, poiché un solo valore medio non è

molto significativo in caso di elevata varianza dei campioni considerati. La motivazione per cui è utile partizionare il carico è duplice: in primo luogo la rappresentatività del modello di carico è incrementata, ed inoltre è molto più elevato anche il potere predittivo del modello stesso. Le tecniche di partizione suddividono il carico in una serie di classi le cui popolazioni sono omogenee secondo un qualche criterio. Il più significativo nell ambito della valutazione delle prestazioni è senza dubbio quello dell utilizzazione delle risorse di sistema A questo punto è necessario partizionare le insieme delle richieste in classi di similarità. I cosiddetti algoritmi di clustering sono delle tecniche che consentono di trovare dei raggruppamenti, detti appunto cluster, nell insieme degli elementi considerati. Questi si basano sull'individuazione di alcuni centroidi, ovvero elementi medi dei cluster, e cercano di assegnare ciascun elemento al cluster più oppurtuno mediante il calcolo della minima distanza da uno dei centroide fissati. Per l'analisi del caso di studio si è deciso di utilizzare il k-means che rientra nella classe degli algoritmi di clustering non-gerarchici.

```
Inputs:
      I = \{i_1, ..., i_k\} (Instances to be clustered)
      n (Number of clusters)
Outputs:
      C = \{c_1, ..., c_n\} (cluster centroids)
      m: I \to C (cluster membership)
procedure KMeans
      Set C to initial value (e.g. random selection of I)
      For each i_i \in I
            m(i_j) = \operatorname{argmin} distance(i_j, c_k)
      End
      While m has changed
             For each j \in \{1..n\}
                   Recompute i_j as the centroid of \{i|m(i)=j\}
             For each i_j \in P
                   m(i_j) = \underset{k \in \{1...n\}}{\operatorname{argmin}} distance(i_j, c_k)
             End
      End
return C
End
```

Figura 2.2: Schema

L'algoritmo K-Means è stato applicato a 10000000 documenti, generati tenendo conto delle varie distribuzioni e suddividendoli in tre classi. Si è deciso di scegliere i centroidi iniziali il più lontano possibile tra loro, prendendo come punti di riferimento i valori minimo, massimo e medio delle dimensioni dei file. I centroidi iniziali sono stati:

- centroide min 1.453304
- centroide max 715827882.666667
- centroide medio 357913940.606681

Si è scelto di far convergere l'algoritmo nel caso in cui la differenza di valori dei centroidi tra due iterazioni successive fosse minore di 10^{-10} ed i risultati sono stati i seguenti: Si può notare come i documenti seguano una distribuzione

Classe	Dimensione(byte)	Richieste
1	10281	9999995
2	279513744	4
3	715827882	1

Tabella 2.1: Risultati clustering

heavy-tailed, dove per heavy tailed si intende dire che vi è un' elevatissima presenza di documenti di piccole dimensioni e una piccola, ma non trascurabile, presenza di documenti di dimensioni maggiori anche di diversi ordini di grandezza. Questo fenomeno è catturato dall'espressione, detta Power-Law, qui riportata

$$P[X > x] = kx^{-\alpha}L(X)$$

in cui L(x) è una funzione che varia molto lentamente. Un caso particolare di questa, è la distribuzione di Pareto in cui la coda della distribuzione è esprimibile con la relazione :

$$P[X > x] = kx^{-\alpha}$$

Proprio per questa caratteristica una singola classe non può approssimare con sufficiente precisione il carico Web, dal momento che la grande variabilità degli elementi riduce il significato statistico delle misurazioni effettuate sui valori medi. Per ogni classe sono state inoltre ricavate le probabilità di arrivo di richieste HTTP, che torneranno utili nel momento in cui si utilizzerà il modello analitico:

Classe	Prob. arrivo richieste classe R
1	0.999995
2	0.0000004
3	0.0000001

Tabella 2.2: specifiche2

Capitolo 3

Simulazione

Il modello simulativo è stato di fondamentale importanza in quanto ha permesso di ricavare i parametri mancanti del sistema. A tal proposito, in questa sezione verranno presentati:

- Introduzione a CSIM
- Rappresentazione del workload
- Rappresentazione delle risorse
- Dimensionamento del sistema
- Esecuzione del transiente
- Presentazione dei risultati

3.1 CSIM

Un simulation engine consiste di un insieme di oggetti e metodi usati per costruire un modello di simulazione. CSIM è un package process-oriented integrabile in programmi C/C++, che realizza un modello di simulazione discreto: next event time advance (event-driven). CSIM consente di modellare il sistema mediante l'utilizzo di speciali processi che interagiscono tra loro

utilizzando delle apposite strutture dati. Il programma mantiene un tempo simulato in modo da consentire lo studio del comportamento del sistema al variare del tempo. CSIM fornisce al programmatore una serie di oggetti, che definiscono le astrazioni di supporto alla costruzione e all'esecuzione del modello simulativo. Gli oggetti principali sono:

Processes: sono le entità attive che sfruttano le risorse disponibili, attendono gli eventi o collezionano statistiche.

Facilities: rappresentano quelle risorse (ad esempio serventi) che vengono utilizzate dai processi attivi.

Events: eventi usati al fine di mantenere una sincronizzazione tra i processi.

Mailboxes: usate per lo scambio di messaggi che realizza le comunicazioni tra i processi.

Data collection structures: apposite strutture dati in grado di collezionare le statistiche rilevate durante la simulazione. Nel caso di studio in esame si è fatto uso anche di boxes e meters, i primi per collezionare statistiche relative ad un sottoinsieme di risorse del sistema, i secondi per stimare il numero di passaggi in un determinato punto della rete.

Process classes: classi definite per caratterizzare i processi nell uso di risorse, nella gestione degli eventi e nella raccolta statistiche.

Stream: flussi di numeri casuali.

A titolo di esempio, si potrebbe dunque rappresentare un sistema di tipo Client/Server come una facility (il server) ed un processo CSIM (il client) che usa la facility. Data la natura del CSIM, brevemente riassunta finora, è evidente come questo offra ottime possibilità di tradurre un modello a reti di code (QN) in un modello simulativo.

3.2 Rappresentazione del workload

La rappresentazione del carico mediante le distribuzioni è stata facilitata in quanto CSIM offre delle funzioni per generare i valori sia secondo la distribuzione Lognormale che secondo la distribuzione Pareto. Per quanto concerne il numero di richieste per sessione, che seguono la distribuzione gaussiana inversa, si è utilizzato l'algoritmo di Michael/Shucany/Haas:

- 1. Si generi V da N(0,1) (distribuzione normale) e si ponga $y=v^2$;
- 2. Si ponga $x_1 = \mu + \mu^2 * \frac{y}{2*\lambda} \circ \frac{\mu}{2*\lambda} * \sqrt{4*\mu*\lambda*y + \mu^2*y^2};$
- 3. Si generi u da U(0,1) (distribuzione uniforme);
- 4. Se $u \leq \frac{\mu}{mu+x_1}$ allora si ponga $x=x_1$, altrimenti si ponga $x=\mu^{\frac{2}{x_1}}$

Il workload cui è sottoposto il sistema per ogni utente è il seguente:

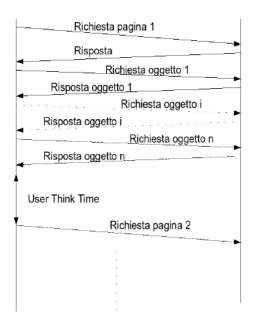


Figura 3.1: Carico

Il singolo utente, durante una sessione, richiede un numero imprecisato di pagine web intervallate da un think time. Ognuna di queste pagine web può poi essere composta di oggetti embedded (nel caso in esame almeno due), come ad esempio fogli di stile, immagini e quant'altro. Di conseguenza il carico è stato generato seguendo quest'approccio:

- 1. Si generano il numero di richieste per sessione che l'utente sottoporrà al sistema
- 2. Si genera la dimensione della pagina da richiedere
- 3. Si richiede ed ottiene il documento
- 4. Si genera il numero di oggetti per la pagina richiesta
- 5. Per ogni oggetto si genera la dimensione e si avvia la richiesta
- 6. Si attende un tempo pari a User Think Time e se sono presenti altre richieste si torna al punto 2.

Si presenta di seguito il frammento di codice rappresentante quest'approccio:

3.3 Rappresentazione delle risorse

Come brevemente introdotto in precedenza, una facility modella in ambiente CSIM una risorsa del sistema, con la rispettiva coda. La libreria mette a disposizione diversi tipologie di facility, scegliendo le più adatte al modello:

- facility risorsa con una sola coda ed un solo servente, occupabile da un solo processo alla volta;
- facility set array di facility di primo tipo e quindi una risorsa con più code e più serventi (una coda per ogni servente) indipendenti tra loro.
- multi-server facility risorsa con una sola coda ma più serventi, occupabili tutti contemporaneamente;

Per realizzare la simulazione sono state utilizzate solo le prime due categorie. Si riporta il codice CSIM in cui avviene la dichiarazione delle suddette facility, che verranno analizzate in seguito:

```
FACILITY cpuWS[NUM_SERVER];

FACILITY diskWS[NUM_DISK*NUM_SERVER];

FACILITY L2;

FACILITY CPU_web_switch;

FACILITY in Link;

FACILITY out Link;

FACILITY LINK\_ADD;

FACILITY LS1;

FACILITY LS2;

FACILITY LW2[NUM_SERVER];

FACILITY LW3[NUM_SERVER];
```

Prima di presentare le domande di servizio per ogni FACILITY, si definiscono dei parametri della rete e alcune funzioni di supporto per consentire una maggiore comprensione:

TCPOV (overhead in byte introdotto dal TCP)	20	
IPOV (overhead in byte introdotto da IP)		
FRAMEOV (overhead in byte introdotto dal tipo di rete fisica)		
MSS (massima dimensione in byte di un pacchetto TCP)		
AVG_SIZE_HTTP_REQ (dimensione media di una richiesta HTTP)	290	

Tabella 3.1: specifiche3

```
int NDatagrams(double m) {
    int n;
    double f;
    f=m/(double)MSS;
    n=(int)ceil(f);
    return n;
}
```

Ndatagrams consente di determinare il numero di messaggi necessari per inviare un messaggio lungo m bytes.

```
int Overhead(double m) {
   return (NDatagrams(m)*(TCPOV+IPOV+FRAMEOV));
}
```

Overhead rappresenta l'overhead necessario per inviare un messaggio lungo m bytes.

```
double NetworkTime(double m, double bandwidth) {
    return (double)(8*(m+Overhead(m)))/(double)(1000*1000*bandwidth);
}
```

NetworkTime consente di calcolare il tempo (in secondi) necessario ad un messaggio lungo m bytes per transitare attraverso una rete caratterizzata da una banda bandwidth (in Mbps). Si presentano di seguito le domande di servizio relative ai componenti della rete (N.B.: non sono presenti le domande di servizio delle schede di rete LS2, LW2 e LW3, poiché si è assunto che il loro transfer rate sia pari alla banda delle reti a cui sono collegate).

```
double D_InLink() {
    return NetworkTime(AVG_SIZE_HTTP_REQ, INLINK_BANDWIDTH) +
        3*NetworkTime(0.0001, INLINK_BANDWIDTH);
}

double D_OutLink(double docSize) {
    return NetworkTime(docSize, OUTLINK_BANDWIDTH) + 2 * NetworkTime(0.0001,
        OUTLINK_BANDWIDTH);
}

double D_LAN(double docSize) {
    if(docSize == 0) {
        return NetworkTime(AVG_SIZE_HTTP_REQ, BANDWIDTH_L2);
    }
    return NetworkTime(docSize, BANDWIDTH_L2);
}
```

Per quanto concerne la domanda di servizio della LAN si è operata una distinzione tra fase di richieste (in cui docSize = 0) e fase di risposta

```
double D_Cpu(double service_rate) {
   return 1 / service_rate;
}
```

La domanda di servizio della CPU vale sia per il Web Server che per il Web Switch, infatti il Service_Rate dev'essere specificato come parametro di input.

```
double D_WSDisk(double doc_size) {
   double ret = (number_of_blocks(doc_size)) * ((DISK_SEEK_TIME/pow(10,3)) +
        ROTATIONAL_LATENCY + (CONTROLLER_TIME/pow(10,3)) + (BLOCK_SIZE/((
        double)DISK_TRANSFER_RATE*pow(10,6))));
   return ret;
}
```

La funzione number_of_blocks indica il numero di blocchi necessari da leggere per un intero documento di dimensione doc_size bytes ed è così definita:

```
int number_of_blocks(double docSize) {
  return ceil(docSize/BLOCK_SIZE);
}
```

I restanti parametri della domanda di servizio del disco sono:

SeekTime: secondi che impiega il braccio del disco a posizionarsi sul cilindro corretto

Controller Time: secondi spesi dal controller del disco per processare una richiesta di I/O

TransferRate: tasso espresso in MB/sec con cui i dati vengono trasferiti dal/al disco

BlockSize: dimensione in bytes del blocco del disco

RotationalLatency: tempo medio in secondi affinchè il settore giusto capiti sotto la testina del braccio del disco

3.4 Dimensionamento del Sistema

Rappresentato il workload e le risorse del sistema, è stato possibile dimensionare i parametri mancanti della rete, adottando un approccio di tipo empirico, iniziando a dimensionare i vari link per poi passare ai web server (CPU e Dischi). I parametri da dimensionare erano i seguenti:

- Banda dell'incoming link;
- Banda dell'outgoing link;
- CPU Web Swtich Service Rate;
- Numero di Web Server
- Numero di dischi per Web Server
- Banda del link Addizionale

Transfer rate delle schede di rete LS1, LS2, LW2, LW3. E' doveroso sottolineare che tutte le schede di rete sono state dimensionate tenendo conto delle reti a cui erano collegate e quindi queste presenteranno un transfer rate pari alla banda della LAN a cui sono accoppiate. Le simulazioni sono state condotte sulla configurazione standard del sistema in cui il server veniva scelto in modo random e i risultati sono stati mediati su 10 run diversi, poiché non è molto corretto attenersi agli esiti di una singola simulazione del sistema. I parametri risultanti sono stati:

Risorsa	Valore
Banda incoming Link	45 Mbps (T3)
Banda Outgoing Link	1000 Mbps
CPU Web Switch Service Rate	$9600 \; { m richieste/secondo}$
Numero di Web Server	66
Numero di dischi per Web Server	12
Transfer Rate LS1	1000 Mbps
Transfer Rate LS2	1000 Mbps
Transfer Rate lw2	1000 Mbps
Transfer Rate LW3	622 Mbps (OC-12)
Banda Link Addizionale	622 Mbps (OC-12)

Tabella 3.2: specifiche4

3.5 Transiente

Un sistema web attraversa una fase iniziale durante la quale le code dei vari serventi cominciano a riempirsi, fino a raggiungere un livello di regime, in cui gli indici di prestazione del sistema assumono valori stabili. E' quindi importante non tenere conto delle statistiche relative al periodo iniziale (transiente o transitorio), in quanto queste potrebbero rischiare di falsare i risultati complessivi. La determinazione della lunghezza del transiente è stata ricavata tramite l'algoritmo di Welch descritto da Law e Kelton in. Esso consente di determinare il numero di osservazioni l (di un indice del sistema Y) che è necessario scartare dal numero totale di osservazioni m. Se l ed m sono scelti troppo piccoli la stima dell'indice potrebbe discostarsi dal caso stazionario; viceversa se l è scelto troppo grande la stima dell'indice rischia di possedere una varianza troppo grande. L'algoritmo proposto da Welch fa uso di una procedura grafica per determinare un valore di l tale che $E[Yi] \approx lim(i \rightarrow \inf)E[Y_i] = \nu peri > l$. Ciò è equivalente a determinare per quale valore di l la curva media del transiente si appiattisce fino a raggiungere il valore ν . In generale è difficile ricavare l'tramite una singola replica, a causa della variabilità dell'indice Y. Per risolvere un tale problema Welch propone una procedura basata sull'utilizzo di n repliche della simulazione indipendenti tra loro. L'algoritmo è il seguente:

- 1. Fare n repliche della simulazione (dove $n \geq 5$), ognuna di lunghezza m (dove m sono le osservazioni fatte nella simulazione), porre Y_{ij} come la i-esima osservazione della j-esima replica ($j=1,2,\ldots,n; i=1,2,\ldots,m$)
- 2. Calcolare Y_i come media delle Y_{ij} di ogni replica

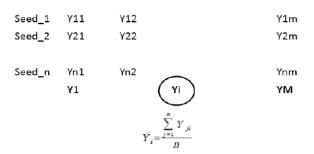


Figura 3.2: Carico

3. Calcolare il valore di Moving average $Y_i(w)$, dove w è la finestra ed è un intero positivo tale che $w \leq \frac{m}{2}$, come segue:

$$Y_w = \{\frac{\sum_{s=-w}^w Y_{i+s}}{2w+1} sei = w+1, \dots, m-w\}$$

4. Graficare la media mobile e si sceglie l = i tale che la media mobile sembra convergere.

Per quanto riguarda il caso di studio in esame, sono state effettuate 3 prove utilizzando la configurazione standard (random), effettuando n=10 repliche della simulazione ognuna di lunghezza m = 500000, graficando il tempo di risposta al variare della finestra W.

Caso 1:
$$n=10$$
, $m = 500000$, $W = 5000$

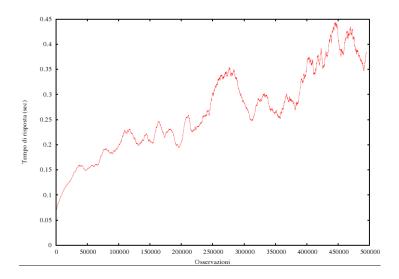


Figura 3.3: Grafico1

Utilizzando una finestra piccola rispetto al numero di osservazioni, si nota un'alta variabilità dei valori osservati e un trend monotono crescente all'aumentare del numero di osservazioni.

Caso2: n=10, m=500000, W=50000

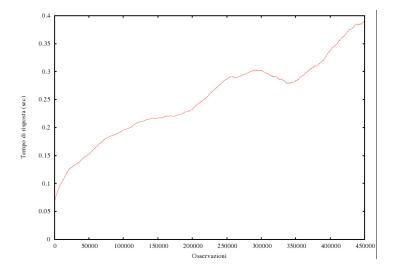


Figura 3.4: Grafico2

In questo caso è sempre presente l'andamento crescente del tempo di risposta, ma la variazione dei valori è molto minore rispetto al caso 1.

Caso3: n=10, m=500000, W=100000

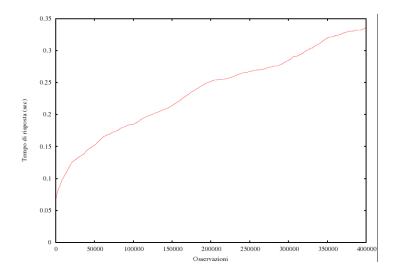


Figura 3.5: Grafico3

Anche in quest'ultimo caso, il tempo di risposta non sembra convergere, nonostante presenti un andamento piuttosto stabile. La mancata convergenza verso un valore potrebbe dipendere dalla distribuzione heavy tailed dei documenti, e dal fatto che i dischi potrebbero essere sottoposti a svolgere delle operazioni per file di centinaia di megabyte (si vedano i risultati del partizionamento del carico). Non essendo stato possibile determinare con precisione il valore l, si è deciso comunque di eliminare dalla simulazione le prime 100000 osservazioni della simulazione, pur avendo la consapevolezza che il tempo di risposta tende ad aumentare al numero di osservazioni.

3.6 Struttura della simulazione

Si presentano di seguito alcuni aspetti ritenuti importanti per comprendere al meglio la simulazione, in modo particolare la generazione di una sessione e delle relative richieste (il processo web client), e il processo principale che si occupa di raccogliere le statistiche.

3.6.1 Webclient

Di seugito si riporta un frammento di codice relativo alla creazione di una sessione e relative richieste.

```
int session = session request(mu session, lambda session);
\quad \textbf{for} \hspace{0.1cm} (\hspace{1mm} i=0\hspace{1mm} ; \hspace{1mm} i \hspace{1mm} < \hspace{1mm} \texttt{session} \hspace{1mm} ; \hspace{1mm} i++) \hspace{1mm} \{
   html page = html page size(mu html, sigma html, alfa html);
  set _process_class(requestClasses[get_doc_class(html_page)]);
   if(variant == PROXY && stream_prob(p_hit_proxy) > 0.4) {
      web\_client (html\_page\,,\ variant\,,\ bool\_transient\,,\ iter\,)\,;
   if(variant != PROXY) {
       web client (html page, variant, bool transient, iter);
   num\_embedded\_objects = object\_per\_request (alfa\_obj);
   for (j=0; j < num embedded objects; j++) {
       emb\_obj\_size = embedded\_object\_size(mu\_emb, sigma\_emb);\\
       set _process_class(requestClasses[get_doc_class(emb_obj_size)]);
       if(\,{\rm variant}\,=\!\!-PROXY\,\&\&\,\,{\rm stream\_prob}\,(\,{\rm p\_hit\_proxy})\,>\,0.4)\ \{
            web client (emb obj size, variant, bool transient, iter);
      if(variant != PROXY) {
           web_client(emb_obj_size, variant, bool_transient, iter);
  hold(user think time(alfa tt));
```

Per ogni richiesta della sessione viene invocata la funzione web_client specifica quali risorse vengono utilizzate e in che misura.

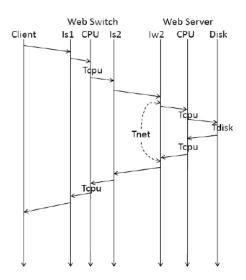


Figura 3.6: webclient

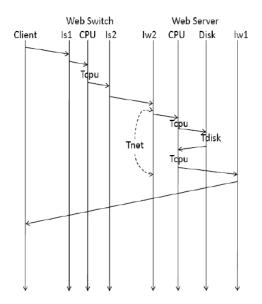


Figura 3.7: webclient2

Si presenta di seguito un frammento della funzione web_client per specificare come avvengono i cicli di richiesta risposta sopra rappresentati. In CSIM questi cicli sono rappresentati da un uso esclusivo delle risorse modellate:

```
use(inLink, D InLink());
switch start time = enter box(WebSwitch);
use(LS1, D LS1in());
use(CPU web switch, D Cpu(CPU WEB SWITCH SERVICE RATE));
use(LS2, D\_LAN(0)); //stessa banda della LAN, in richiesta doc size=0
exit box (WebSwitch, switch start time);
use(L2, D_LAN(0));
/* random */
if(variant == RANDOM || variant == LINK\ ADD || variant == PROXY) {
    tmp server = current server;
    current server = csim random int(0, NUM SERVER-1);
else if (variant == ROUND ROBIN) { //round\ robin}
    tmp_server = current_server;
    \verb|current_server| = (tmp_server+1)\% NUM_SERVER;
// least loaded
else if (variant == LEAST LOADED) {
  tmp server = get least_loaded();
server start time = enter box(WebServer);
use(LW2[tmp\_server], D\_LAN(0));
use(cpuWS[tmp\_server], D\_Cpu(CPU\_SERVICE\_RATE));\\
//selezione del disco round robin
tmp disk = currentDisk[tmp server];
currentDisk[tmp\_server] = (tmp\_disk+1)%NUM DISK;
use(diskWS[tmp server*NUM DISK + tmp disk], D WSDisk(doc size));
use(cpuWS[tmp server], D Cpu(CPU SERVICE RATE));
if (variant != LINK\ ADD) {
    use(LW2[tmp_server], D_LAN(doc_size));
else {
   use(LW3[tmp server], D linkAdd(doc size));
exit box(WebServer, server start time);
if(variant == LINK \setminus ADD) {
  use(LINK\ ADD, D linkAdd(doc size));
else {
  use(L2, D_LAN(doc_size));
  use(LS2, D LAN(doc size));
  use(CPU web switch, D Cpu(CPU WEB SWITCH SERVICE RATE));
  use(LS1, D_LS1out(doc_size));
  use(outLink, D OutLink(doc size));
```

Dal frammento di codice sopra riportato si può notare come sia il web switch che i web server sono stati modellati attraverso dei BOXES (che servono per collezionare statistiche relative ad un sottoinsieme delle risorse di un sistema), inoltre si può notare come alcuni componenti nel caso sia presente il link addizionale siano molto meno utilizzati (come ad esempio il web switch o la LAN L2).

3.6.2 Il processo principale

Ogni client è rappresentato come appena discusso da un processo CSIM. Ogni processo viene creato da un processo principale secondo una particolare legge degli arrivi (in questo caso esponenziale). Il processo principale si occupa inoltre di reimpostare le statistiche raccolte una volta superato il periodo di transiente in maniera da escludere dalle considerazioni finali quelli che sono valori non particolarmente aderenti alla realtà perché ottenuti in condizioni del sistema non standard (carico minino, code vuote etc.). La simulazione procede, grazie al costrutto while e la condizione di convergenza, finché non vengono raccolti valori tali da ottenere dei risultati considerati rilevanti (con un certo grado di confidenza) Nel caso in esame si è scelto un livello di confidenza del 98% con un errore relativo di 0.005. Il codice che realizza tutto questo è di seguito riportato.

```
report _ table(rtime);
report _ boxes();
meter_summary();
tabulate(resptime, table_mean(rtime));
statistics(i, variante);
rerun();
...
}
```

Dal frammento di codice sopra riportato si può notare il ciclo for e la funzione rerun() che consentono di eseguire più simulazioni e quindi di ottenere risultati più accurati; inoltre si può notare come siano stati scartati i valori relativi al transiente. E' opportuno sottolineare come alla condizione di convergenza sia stata aggiunta un'ulteriore condizione basata sul numero di osservazioni, poiché come visto nello studio del transiente, la convergenza potrebbe non verificarsi per tutte le iterazioni.

3.7 Presentazione dei risultati

Si presentano di seguito i risultati mediati su 10 iterazioni, per ogni componente del sistema preso in esame e per tutte le varianti analizzate. Le statistiche riportate sono l'utilizzazione, la lunghezza media delle coda e il tempo di risposta per ogni classe di richiesta.

3.7.1 Risultati Random

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	0.6673596	0.0000002	0.0000001	0.6673599
disco i-esimo:	0.2901815	0.0000000	0.0000000	0.2901815
inLink:	0.3070558	0.0000002	0.0000001	0.3070561
outLink:	0.2779962	0.0000000	0.0000000	0.2779962
cpu web switch:	0.6882190	0.0000003	0.0000001	0.6882193
LAN:	0.2774720	0.0000000	0.0000000	0.2774720
LS1:	0.2917997	0.0000000	0.0000000	0.2917997
LS2:	0.2774737	0.0000000	0.0000000	0.2774737
LW2: 0.0042041 0.0000000 0.0000000	0.0042041			

Tabella 3.3: Utilizzazioni

Come si può notare, il vincolo sull'utilizzazione richiesto nelle specifiche del progetto è stato rispettato, con la risorsa collo di bottiglia (CPU Web Switch) che presenta un'utilizzazione del 68,8%. Le altre risorse, ad eccezione della CPU del web server, presentano un'utilizzazione piuttosto basse.

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	1.5556346	0.0000003	0.0000001	1.5556350
disco i-esimo:	1.6398481	0.0000002	0.0000000	1.6398483
inLink:	0.8287492	0.0000002	0.0000001	0.8287495
outLink:	4.2762899	0.0000000	0.0000000	4.2762899
cpu web switch:	3.6788684	0.0000005	0.0000003	3.6788692
LAN:	1.6334769	0.0000001	0.0000000	1.6334770
LS1:	3.3884849	0.0000000	0.0000000	3.3884849
LS2:	2.7263059	0.0000002	0.0000001	2.7263062
LW2:	0.0044529	0.0000000	0.0000000	0.0044529

Tabella 3.4: Lunghezza code

Per quanto concerne la lunghezza della coda, si nota un accodamento delle risposte nel link di uscita, che presenta valori più alti persino del web switch. I tempi medi di risposta per la Classe1 evidenziano una lentezza generale dei

Centro	Classe1	Classe2	Classe3
cpu web server i-esimo:	0.0155025	0.0000349	0.0000133
disco i-esimo:	0.8416113	0.0000000	0.0000000
inLink:	0.0002501	0.0000286	0.0000122
outlink:	0.0012935	0.0000000	0.0000000
cpu web switch:	0.0005546	0.0000599	0.0000377
LAN:	0.0002467	0.0000079	0.0000003
LS1:	0.0005116	0.0000013	0.0000004
LS2:	0.0004116	0.0000223	0.0000111
LW2:	0.0000445	0.0000000	0.0000000

Tabella 3.5: Tempo medio di risposta

dischi nel soddisfare le richieste. Per le altre due classi non è possibile fare alcun tipo di assunzione, dato il limitato numero di osservazioni di Classi 2 e 3 a cui è sottoposto il sistema e dato il limite temporale della simulazione, che non permette alle richieste di queste due classi di essere soddisfatte (non mi piace molto la cosa del limitato numero di osservazioni). Risultati sicuramente più significativi per le Classi superiori saranno osservabili nel momento in cui verranno presentati i risultati del modello analitico.

3.7.2 Risultati Round Robin

Le utilizzazioni delle varie risorse adottando la politica round robin sono quasi identiche a quelle con politica random presentate precedentemente. Rispetto al caso presentato precedentemente, si nota un leggero aumento delle code dei dischi del web server e della cpu del web switch, mentre si ha una leggera diminuzione o valori analoghi per tutte le altre risorse. Anche per quanto

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	0.6747827	0.0000003	0.0000001	0.6747830
disco i-esimo:	0.2937349	0.0000000	0.0000000	0.2937349
inLink:	0.3104327	0.0000002	0.0000001	0.3104331
outLink:	0.2814336	0.0000000	0.0000000	0.2814336
cpu web switch:	0.6958719	0.0000003	0.0000001	0.6958723
LAN:	0.2809161	0.0000000	0.0000000	0.2809161
LS1:	0.2954094	0.0000000	0.0000000	0.2954094
LS2:	0.2809159	0.0000000	0.0000000	0.2809159
LW2: 0.0042562 0.0000000 0.0000000	0.0042562			

Tabella 3.6: Utilizzazioni

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	1.0056119	0.0000004	0.0000001	1.0056125
disco i-esimo:	1.6242344	0.0000000	0.0000002	1.6242346
inLink:	0.8558574	0.0000002	0.0000005	0.8558581
outLink:	4.4133256	0.0000000	0.0000000	4.4133256
cpu web switch:	3.9749297	0.0000004	0.0000003	3.9749304
LAN:	1.6945618	0.0000001	0.0000000	1.6945619
LS1:	3.4855153	0.0000006	0.0000000	3.4855159
LS2:	2.8162152	0.0000000	0.0000001	2.8162153
LW2:	0.0045441	0.0000000	0.0000000	0.0045441

Tabella 3.7: Lunghezza Code

Centro	Classe1	Classe2	Classe3
cpu web server i-esimo:	0.0099264	0.0000537	0.0000101
disco i-esimo:	0.5745555	0.0000000	0.0000000
inLink:	0.0002556	0.0000278	0.0000574
outlink:	0.0013225	0.0000000	0.0000000
cpu web switch:	0.0005932	0.0000531	0.0000403
LAN:	0.0002535	0.0000113	0.0000003
LS1:	0.0005215	0.0000742	0.0000004
LS2:	0.0004213	0.0000008	0.0000151
LW2:	0.0000449	0.0000000	0.0000000

Tabella 3.8: Tempo medio di risposta

riguarda i tempi medi di risposta, i risultati sono analoghi al caso precedente, fatta eccezione per i dischi del web server che presentano un leggero aumento dei tempi, dovuti all'aumento delle code.

3.7.3 Risultati Least Loaded

Adottando questa politica diminuiscono i tempi medi di servizio e di conseguenza si ha un aumento del carico del sistema. Per questo motivo è possibile notare un aumento delle utilizzazioni per tutte le risposte del sistema, che porta a superare la soglia del 70% sia per la CPU del web switch che per quella del Web Server. Come avviene per le utilizzazioni, anche la lunghezza media delle code aumenta per tutti i centri, ad eccezione dei dischi del web server, poiché non accade mai che un server particolarmente carico riceva altre richieste da far processare ai suoi dischi se prima le code non sono state svuotate I tempi di risposta sono più o meno analoghi a quelli presentati in precedenza, fatta eccezione per i dischi del web server, che, come ci si poteva aspettare, riducono il loro tempo medio di risposta.

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	0.7167869	0.0000002	0.0000001	0.7167871
disco i-esimo:	0.3128002	0.0000000	0.0000000	0.3128002
inLink:	0.3294591	0.0000002	0.0000001	0.3294594
outLink:	0.2996635	0.0000000	0.0000000	0.2996635
cpu web switch:	0.7392626	0.0000002	0.0000001	0.7392628
LAN:	0.2990815	0.0000000	0.0000000	0.2990815
LS1:	0.3144901	0.0000000	0.0000000	0.3144901
LS2:	0.2990815	0.0000000	0.0000000	0.2990815
LW2: 0.0045316 0.0000000 0.0000000	0.0045316			

Tabella 3.9: Utilizzazioni

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	3.9782364	0.0000012	0.0000006	3.9782382
disco i-esimo:	0.6957288	0.0000000	0.0000000	0.6957288
inLink:	1.0129555	0.0000002	0.0000001	1.0129558
outLink:	5.6197781	0.0000000	0.0000000	5.6197781
cpu web switch:	6.0216761	0.0000009	0.0000001	6.0216771
LAN:	2.0022744	0.0000002	0.0000000	2.0022746
LS1:	4.5046757	0.0000000	0.0000000	4.5046757
LS2:	3.6126354	0.0000000	0.0000000	3.6126354
LW2:	0.0051400	0.0000000	0.0000000	0.0051400

Tabella 3.10: Lunghezza Code

Centro	Classe1	Classe2	Classe3
cpu web server i-esimo:	0.0365676	0.0001307	0.0000703
disco i-esimo:	0.1738966	0.0000000	0.0000000
inLink:	0.0002853	0.0000227	0.0000093
outlink:	0.0015856	0.0000000	0.0000000
cpu web switch:	0.0008480	0.0000995	0.0000137
LAN:	0.0002824	0.0000231	0.0000003
LS1:	0.0006352	0.0000008	0.0000004
LS2:	0.0005094	0.0000005	0.0000003
LW2:	0.0000495	0.0000000	0.0000000

Tabella 3.11: Tempo medio di risposta

3.7.4 Risultati Proxy

L'introduzione del proxy, con un cache hit rate del 40%, porta ad un notevole calo delle utilizzazioni, riducendo a meno del 46% l'utilizzazione della risorsa collo di bottiglia del sistema (la CPU del web switch) e della CPU del Web Server. Anche le code tendono a diminuire notevolmente, come era logico aspettarsi. Analogo discorso vale anche per i tempi medi di risposta. Si ricorda che per l'esecuzione della simulazione con l'introduzione del proxy (e con il link addizionale, che sarà presentato nella prossima sezione), è stata adottata la politica random.

3.7.5 Risultati Link Addizionale

L'introduzione del link addizionale comporta una notevole diminuzione dell'utilizzazione della cpu del web switch e della maggior parte delle componenti di rete, come la LAN L2 e le schede di rete LS1, LS2 e LW2, poiché queste hanno il compito di gestire solamente le richieste, mentre le risposte vengono interamente smistate verso la scheda di rete LW3 e il link addizionale. Anche la lunghezza media delle code dello switch e delle componenti di rete tende

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	0.4382355	0.0000001	0.0000000	0.4382356
disco i-esimo:	0.1921759	0.0000000	0.0000000	0.1921759
inLink:	0.2014804	0.0000001	0.0000000	0.2014805
outLink:	0.1842500	0.0000000	0.0000000	0.1842500
cpu web switch:	0.4519287	0.0000001	0.0000000	0.4519288
LAN:	0.1838706	0.0000000	0.0000000	0.1838706
LS1:	0.1933170	0.0000000	0.0000000	0.1933170
LS2:	0.1838711	0.0000000	0.0000000	0.1838711
LW2: 0.0027859 0.0000000 0.0000000	0.0027859			

Tabella 3.12: Utilizzazioni

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	0.6329342	0.0000002	0.0000000	0.6329343
disco i-esimo:	0.9622401	0.0000000	0.0000000	0.9622401
inLink:	0.3370955	0.0000001	0.0000000	0.3370956
outLink:	2.1766564	0.0000000	0.0000000	2.1766564
cpu web switch:	0.9132859	0.0000002	0.0000000	0.9132861
LAN:	0.8057551	0.0000000	0.0000000	0.8057551
LS1:	1.7810221	0.0000057	0.0000000	1.7810278
LS2:	1.3518652	0.0000001	0.0000000	1.3518653
LW2:	0.0029656	0.0000000	0.0000000	0.0029656

Tabella 3.13: Lunghezza Code

Centro	Classe1	Classe2	Classe3
cpu web server i-esimo:	0.0096208	0.0000288	0.0000000
disco i-esimo:	1.0033886	0.0000000	0.00000000
inLink:	0.0001552	0.0000186	0.00000000
outlink:	0.0010055	0.0000000	0.00000000
cpu web switch:	0.0002102	0.0000291	0.0000000
LAN:	0.0001859	0.0000005	0.0000000
LS1:	0.0004110	0.0011045	0.0000000
LS2:	0.0003119	0.0000110	0.0000000
LW2:	0.0000451	0.0000000	0.0000000

Tabella 3.14: Tempo medio di risposta

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	0.6729036	0.0000003	0.0000001	0.6729039
disco i-esimo:	0.2926927	0.0000000	0.0000000	0.2926927
inLink:	0.3096163	0.0000002	0.0000001	0.3096167
outLink:	0.0000000	0.0000000	0.0000000	0.0000000
cpu web switch:	0.3475399	0.0000003	0.0000001	0.3475402
LAN:	0.0090708	0.0000000	0.0000000	0.0090708
LS1:	0.0139327	0.0000000	0.0000000	0.0139327
LS2:	0.0090708	0.0000000	0.0000000	0.0090708
LW2: 0.0001374 0.0000000 0.0000000	0.0001374			
LINK_ADD:	0.4508218	0.0000000	0.0000000	0.4508218
LW3:	0.0068306	0.0000000	0.0000000	0.0068306

Tabella 3.15: Utilizzazioni

Centro	Classe1	Classe2	Classe3	Totale
cpu web server i-esimo:	1.5404288	0.0000006	0.0000001	1.5404295
disco i-esimo:	1.6460958	0.0000006	0.0000000	1.6460963
inLink:	0.4752640	0.0000007	0.0000001	0.4752647
outLink:	0.0000000	0.0000000	0.0000000	0.0000000
cpu web switch:	0.4067200	0.0000004	0.0000001	0.4067205
LAN:	0.0090708	0.0000000	0.0000000	0.0090708
LS1:	0.0139327	0.0000000	0.0000000	0.0139327
LS2:	0.0090708	0.0000000	0.0000000	0.0090708
LW2:	0.0001374	0.0000000	0.0000000	0.0001374
LINK_ADD:	3.5259678	0.0000000	0.0000000	3.5259678
LW3:	0.0071490	0.0000000	0.0000000	0.0071490

Tabella 3.16: Lunghezza Code

a diminuire notevolmente, mentre restano immutate quelle dei web server. Quanto evidenziato in precedenza, risulta essere valido anche per il tempo medio di risposta.

Centro	Classe1	Classe2	Classe3
cpu web server i-esimo:	0.0152177	0.0000734	0.0000101
disco i-esimo:	0.8363018	0.0000000	0.0000000
inLink:	0.0001423	0.0000773	0.0000093
outlink:	0.0000000	0.0000000	0.0000000
cpu web switch:	0.0001219	0.0000428	0.0000104
LAN:	0.0000027	0.0000008	0.0000003
LS1:	0.0000042	0.0000013	0.0000004
LS2:	0.0000027	0.0000008	0.0000003
LW2:	0.0000027	0.0000000	0.0000000
LINK_ADD:	0.0010579	0.0000000	0.0000000
LW3:	0.0001419	0.0000000	0.0000000

Tabella 3.17: Tempo medio di risposta

Capitolo 4

Modello Analitico

Dal modello simulativo è stato possibile ricavare il tasso di arrivo di richeste HTTP, dato fondamentale per poter eseguire un modello analitico. Dalla configurazione standard si è ricavato il valore:

$$\lambda = 3308.79 \frac{richieste}{sec}$$

Le probabilità di arrivo di richieste di classe r, sono date dalla formula:

$$p_r = \frac{count_r}{observation(scrivereperbene)}$$

Di seguito si riportano nuovamente i valori già presentati nel capitolo 2

Classe	Dimensione(byte)	Richieste
1	10281	9999995
2	279513744	4
3	715827882	1

Tabella 4.1: Risultati clustering

Classe	Prob. arrivo richieste classe R
1	0.999995
2	0.0000004
3	0.000001

Tabella 4.2: specifiche2

Il tasso di richieste per la singola classe è dato dalla formula:

$$\lambda_r = \lambda * p_r$$

Formule indici di prestazione: (inserire le formule di utilizzazione, lunghezza coda e tempi di residenza tramite un editor, per ora sono scritte a cazzo). Utilizzazione:

$$U_{i,r} = \lambda_r * D_{i,r}$$

$$U_i(vettore) = \sum_{1}^{NUM_CLASSES} U_{i,r}$$

Lunghezza coda:

$$n_{i,r} = \frac{U_{i,r}}{1 - U_{i,r}}$$

$$n_i(vettore) = \sum_{1}^{NUM_CLASSES} n_{i,r}$$

Tempo di residenza:

$$R_{i,r} = \frac{D_{i,r}}{1 - U_{i,r}}$$

Per $D_{i,r}$ si intende la domanda di servizio della risorsa i-esima per richieste di classe r-esima. Per quanto concerne le domande di servizio, queste sono le stesse presentate nel modello simulativo, con la differenza che in questo caso, quando è necessario fornire la dimensione del documento, per la classe r bisogna usare il centroide r-esimo. I risultati ottenuti per le componenti del web server dovranno poi essere opportunamente mediati per il numero di server (nel caso delle schede di rete e delle CPU) e per il numero di server moltiplicato per il numero di dischi (nel caso dei dischi dei web server).

Questa assunzione è valida nel caso il carico sia equamente ripartito tra i server e i dischi.

4.1 Presentazione dei risultati

Si presentano di seguito i risultati ottenuti applicando il modello analitico, sia alla rete in configurazione standard che nelle sue varianti.

4.1.1 Risultati standard

Centro	Classe1	Classe2	Classe3	Totale
L2:	0.286753040	0.003004982	0.001923920	0.291681942
inLink:	0.307055735	0.000000123	0.000000031	0.307055889
outLink:	0.287494007	0.003077099	0.001970093	0.292541199
cpu web switch:	0.689330905	0.000000276	0.000000069	0.68933125
cpu web server:	0.668442090	0.000000267	0.000000067	0.668442424
disco web server:	0.323036672	0.002939248	0.001881830	0.32785775
LS1:	0.301311515	0.003077104	0.001970095	0.306358714
LS2:	0.286753040	0.003004982	0.001923920	0.291681942
LW2:	0.004344743	0.000045530	0.000029150	0.004419423

Tabella 4.3: Utilizzazioni

Dalla tabella presentata si può notare che, anche attraverso la risoluzione analitica, i vincoli sulle utilizzazioni sono rispettati e che sono molto simili a quelli presentati nel modello simulativo, se si escludono una differenza di circa il 3% per quanto riguarda l'utilizzazione dei dischi. Come era logico aspettarsi, data la natura della formula che rappresenta la lunghezza della coda, le risorse più utilizzate sono quelle che presentano i valori più alti. In questa tabella si notano immediatamente i valori spropositati dei tempi di residenza dei dischi del web server nel caso di richieste di Classe 2 e 3.

Centro	Classe1	Classe2	Classe3	Totale
L2:	0.402038923	0.003014039	0.001927629	0.406980591
inLink:	0.443117507	0.000000123	0.000000031	0.443117661
outLink:	0.403496967	0.003086597	0.001973982	0.408557546
cpu web switch:	2.218858963	0.000000276	0.000000069	2.218859308
cpu web server:	2.016064373	0.000000267	0.000000067	2.016064707
disco web server:	0.477184891	0.002947912	0.001885377	0.48201818
LS1:	0.431253014	0.003086602	0.001973984	0.4363136
LS2:	0.402038923	0.003014039	0.001927629	0.406980591
LW2:	0.004363702	0.000045532	0.000029151	0.004438385

Tabella 4.4: Lunghezza Code

Centro	Classe1	Classe2	Classe3
L2:	0.000117695	2.277294228	5.825778128
inLink:	0.000133921	0.000092800	0.000092800
outLink:	0.000121947	2.332118913	5.965873728
cpu web switch:	0.000670596	0.000208333	0.000208333
cpu web server:	0.040214192	0.013333337	0.013333334
disco web server:	0.114220190	1764.048526653	4512.885306683
LS1:	0.000130336	2.332123114	5.965877921
LS2:	0.000117695	2.277294228	5.825778128
LW2:	0.000084312	2.270554378	5.814739298

Tabella 4.5: Tempo di residenza

Questi valori sono dovuti al fatto che i file appartenenti a queste due classi sono dell'ordine di centinaia di megabyte e dunque le operazioni di lettura dal disco richiedono svariati minuti per essere completate (si ricorda al lettore che i centroidi di classe 2 e 3 hanno una dimensione rispettivamente di 279 MB e 715 MB).

4.1.2 Risultati proxy

Centro	Classe1	Classe2	Classe3	Totale
L2:	0.172051824	0.001802989	0.001154352	0.175009165
inLink:	0.184233441	0.000000074	0.000000018	0.184233533
outLink:	0.172496404	0.001846259	0.001182056	0.175524719
cpu web switch:	0.413598543	0.000000165	0.000000041	0.413598749
cpu web server:	0.401065254	0.000000160	0.000000040	0.401065454
disco web server:	0.193822003	0.001763549	0.001129098	0.19671465
LS1:	0.180786909	0.001846263	0.001182057	0.183815229
LS2:	0.172051824	0.001802989	0.001154352	0.175009165
LW2:	0.002606846	0.000027318	0.000017490	0.002651654

Tabella 4.6: Utilizzazioni

Le utilizzazioni, nel caso dell'introduzione del proxy server, tendono a diminuire notevolmente, in modo particolare se si considerano le CPU del Web Switch e dei Web Server. Anche in questo caso, i risultati sono molto simili a quelli ottenuti col modello simulativo. L'introduzione del proxy comporta anche un minore accodamento delle richieste. Si può notare infatti come ogni centro presenti delle code inferiori ad uno. L'introduzione del proxy server non risolve il problema della gestione di file di Classe 2 e 3, infatti rispetto al caso standard le differenze tra i tempi di residenza sono minime.

Centro	Classe1	Classe2	Classe3	Totale
L2:	0.207805064	0.001806246	0.001155686	0.210766996
inLink:	0.225840884	0.000000074	0.000000018	0.225840976
outLink:	0.208453963	0.001849674	0.001183455	0.211487092
cpu web switch:	0.705316364	0.000000165	0.000000041	0.70531657
cpu web server:	0.669630968	0.000000160	0.000000040	0.669631168
disco web server:	0.240420855	0.001766664	0.001130374	0.243317893
LS1:	0.220683618	0.001849678	0.001183456	0.223716752
LS2:	0.207805064	0.001806246	0.001155686	0.210766996
LW2:	0.002613659	0.000027319	0.000017490	0.002658468

Tabella 4.7: Lunghezza Code

Centro	Classe1	Classe2	Classe3
L2:	0.000101390	2.274551992	5.821289614
inLink:	0.000113758	0.000092800	0.000092800
outLink:	0.000105000	2.329243139	5.961166833
cpu web switch:	0.000355274	0.000208333	0.000208333
cpu web server:	0.022261746	0.013333335	0.013333334
disco web server:	0.095912913	1761.970872492	4509.484474463
LS1:	0.000111160	2.329247330	5.961171019
LS2:	0.000101390	2.274551992	5.821289614
LW2:	0.000084165	2.270513026	5.814671497

Tabella 4.8: Tempo di residenza

4.1.3 Risultati Link Addizionale

Centro	Classe1	Classe2	Classe3	Totale
L2:	0.008995768	0.000000004	0.000000001	0.008995773
inLink:	0.307055735	0.000000123	0.000000031	0,307055889
cpu web switch:	0.344665453	0.000000138	0.000000034	0.344665625
cpu web server:	0.668442090	0.000000267	0.000000067	0.668442424
disco web server:	0.323036672	0.002939248	0.001881830	0.32785775
linkAdd:	0.462209015	0.004947104	0.003167353	0.470323472
LS1:	0.013817508	0.000000006	0.000000001	0.013817515
LS2:	0.008995768	0.000000004	0.000000001	0.008995773
LW2:	0.000136300	0.000000000	0.000000000	0.0001363
LW3:	0.007003167	0.000074956	0.000047990	0.007126113

Tabella 4.9: Utilizzazioni

Come già evidenziato nel modello simulativo, l'introduzione del link addizionale permette di ridurre notevolmente le utilizzazioni del web switch e delle componenti di rete "interne" (LS1, LS2, L2, LW2). In questo caso la risorsa collo di bottiglia diventa la CPU del Web Server. Anche in quest'ultimo caso, le differenze rispetto alle utilizzazioni ottenuti col modello simulativo sono minime. Le code risultano essere tutte minori di uno, ad eccezione della CPU del Web Server che presenta un valore pari a 2 a causa dell'alta utilizzazione. Le considerazioni fatte sui tempi di residenza nei due casi precedenti sono valide anche in quest'ultimo caso.

Centro	Classe1	Classe2	Classe3	Totale
L2:	0.009077427	0.000000004	0.000000001	0.009077432
inLink:	0.443117507	0.000000123	0.000000031	0.443117661
cpu web switch:	0.525938170	0.000000138	0.000000034	0.525938342
cpu web server:	2.016064373	0.000000267	0.000000067	2.016064707
disco web server:	0.477184891	0.002947912	0.001885377	0.48201818
linkAdd:	0.859458465	0.004971700	0.003177417	0.867607582
LS1:	0.014011107	0.000000006	0.000000001	0.014011114
LS2:	0.009077427	0.000000004	0.000000001	0.009077432
LW2:	0.000136318	0.0000000000	0.000000000	0.000136318
LW3:	0.007052557	0.000074962	0.000047992	0.007175511

Tabella 4.10: Lunghezza Code

Centro	Classe1	Classe2	Classe3
L2:	0.000002743	0.000002719	0.000002719
inLink:	0.000133921	0.000092800	0.000092800
cpu web switch:	0.000317904	0.000208333	0.000208333
cpu web server:	0.040214192	0.013333337	0.013333334
disco web server:	0.114220190	1764.048526653	4512.885306683
linkAdd:	0.000259750	3.756433553	9.602956788
LS1:	0.000004235	0.000004176	0.000004176
LS2:	0.000002743	0.000002719	0.000002719
LW2:	0.000002719	0.000002719	0.000002719
LW3:	0.000140677	3.738130279	9.573000246

Tabella 4.11: Tempo di residenza

Capitolo 5

Conclusioni

Sulla base dei risultati ottenuti e sui problemi riscontrati durante lo sviluppo, si vogliono effettuare alcune considerazioni. Per quanto riguarda il modello simulativo, l'adozione di una politica round robin piuttosto che random non comporta alcuna differenza significativa, mentre l'adozione di una politica di tipo least loaded comporta un aumento dell'utilizzazione (e quindi del carico sottoposto al sistema), mentre tendono a diminuire i tempi medi di risposta. L'introduzione di componenti addizionali (il proxy e il link addizionale) tendono a far diminuire le utilizzazioni e le code del sistema, ma non comportano una diminuzione dei tempi di risposta. Per quanto concerne il modello analitico invece, si nota come i valori delle utilizzazioni siano molto simili a quelli ottenuti col modello simulativo (le differenze maggiori sono intorno al 4% e solo nel caso dei dischi), mentre le lunghezze delle code risultano essere piuttosto diverse tra i due modelli (questo potrebbe essere dovuto al fatto che si assume che il carico sia equamente ripartito tra i server e di conseguenza tra i dischi). I tempi medi di residenza inoltre evidenziano come i dischi siano sottoposti a operazioni molto onerose in caso di richieste di Classe 2 e 3. Nel modello simulativo invece le richieste di Classe 2 e 3 sono molto rare e infatti i valori presentati per le richieste di Classe 1 sono sempre più alti rispetto alle restanti classi. Di conseguenza, il modello simulativo riflette meglio la distribuzione non uniforme delle richieste. Per

quanto concerne i problemi riscontrati durante lo sviluppo dell'applicativo, è doveroso sottolineare come l'utilizzo delle distribuzioni per la generazione delle pagine HTML e degli oggetti embedded abbia portato ad ottenere file di dimensioni di centinaia di megabyte, che hanno portato a tempi medi di residenza spropositati (si vedano i risultati nel modello analitico). Il problema di avere file di queste dimensioni si riflette sicuramente anche nel calcolo del transiente, che come si è visto non consente di trovare un valore tale per cui la media mobile sembra convergere, ma si assiste ad un andamento crescente dei tempi di risposta, come se il sistema fosse ancora in fase di carica. Questo problema si è poi ripercosso anche sul calcolo degli indici nel modello simulativo (e di conseguenza in quello analitico, visto che il fattore lambda è stato ricavato dalla simulazione), poiché sono state escluse solo le prime 100000 osservazioni dalla simulazione (numero non sufficiente per superare il transiente) e di conseguenza i valori ottenuti potrebbero non essere sufficientemente accurati. L'utilizzo di un carico reale, utilizzato nell'esercizio 2 d'esame, avrebbe sicuramente permesso di ottenere dei risultati più affidabili. Una possibile soluzione a questi problemi, potrebbe essere rappresentata dall'utilizzo di un valore di soglia che impedisce di ritenere valide delle richieste superiori a tali soglia, ma che tuttavia non impedisca di avere una distribuzione heavy-tailed (??? non mi piace molto come conclusione né tanto meno come soluzione).

Capitolo 6

Appendice

6.1 common.h

```
#ifndef COMMON H
#define COMMON H
#include <csim.h>
\#define _ISOC99_SOURCE
#define BLOCK_SIZE 2048 //dimensione in byte
#define MBYTE 1048576 //equivalente di un mega espresso in byte
#define ARRIVAL 150 //richieste/sec da parte degli utenti
#define CPU_SERVICE_RATE 150 //richieste/secondo tasso servizio CPU
\# \mathrm{d\,efin\,e}\ \mathrm{SEEK\_TIME\_DISK}\ 8.5\ //\,millisecondi
\#define CONTROLLER\_TIME 0.2 //millisecondi
\#define ROTATIONAL SPEED 7200 //RPM
#define TRANSFER RATE 100 //MB/sec
\#define BANDWIDTH L2 1024 // Mbps
#define CPU WEB SWITCH SERVICE RATE 9600 //richieste/secondo tasso servizio
    C\!PU \quad s \ w \ i \ t \ c \ h
\#define NUM SERVER 66
#define NUM DISK 12
\#define BANDWIDTH LINKADD 622 //Mbps
\#define INLINK BANDWIDTH 45 //Mbps
#define OUTLINK BANDWIDTH 1000 //Mbps
#define LS1 TRANSFER RATE 1000 //Mbps
#define P HIT 0.4 //probabilita ' che la risorsa richiesta sia conservata nel
     p roxy
```

```
#define MAX SERVERS 5000
#define MAX PROCESSES 100000000
#define MAX FACILITIES 5000
\#define MAX CLASSES 10
\#define MAX\_OBSERVATION 400000
\# define NUM\_CLASSES 3 //uguale a K
#define K 3//numero di cluster
#define NUM ITERATIONS 10
#define SEED 3
// \, d\, efinizion\, e \quad d\, elle \quad v\, a\, ri\, a\, n\, t\, i
\#define RANDOM 0
\#define ROUND ROBIN 1
#define LEAST LOADED 2
#define LINK ADD 3
#define PROXY 4
//variabili CSIM
{\tt FACILITY\ cpuWS\,[NUM\_SERVER]}\;;
FACILITY diskWS [NUM DISK*NUM SERVER];
BOX WebServer;
BOX WebSwitch;
FACILITY L2;
FACILITY CPU_web_switch;
FACILITY in Link;
FACILITY outLink;
FACILITY \ link\_add;
FACILITY LS1;
FACILITY LS2;
FACILITY LW2[NUM SERVER];
FACILITY LW3[NUM SERVER];
TABLE wsrtime;
TABLE rtime;
METER lambda;
CLASS request Classes [K];
#endif
```

6.2 cluster.c

```
\#include < stdio.h >
\#include < stdlib.h>
\#include < math.h >
\#include < sys/types.h>
\#include < sys/stat.h>
\#include < stdarg.h>
\#include < string.h >
\#include < csim.h >
\#include "gaussiana_inversa.h"
#include "client.h"
extern double mu session;
extern double lambda session;
extern double alfa tt;
extern double alfa_obj;
extern double mu html;
extern double sigma html;
extern double alfa_html;
extern double mu emb;
extern double sigma_emb;
extern STREAM sess req 1;
extern STREAM sess req 2;
extern STREAM user tt;
extern STREAM object_req;
extern STREAM html 1;
extern STREAM html 2;
extern STREAM obj size;
//Algoritmo di clustering K-Means
void cluster(double *array , int array length , int k)
{
         int i= 0;
         int j = 0;
         int iter = 0;
         int counter = 0;
         int converged = 0;
         double distance = 0.0;
         \mathbf{double} \ \operatorname{distance\_temp} \ = \ 0.0;
         double min = array[0];
         \mathbf{double}\ \max\ =\ \mathtt{array}\ [\ 0\ ]\ ;
         \mathbf{double} \ * \mathtt{centroids} \ = \ (\mathbf{double*}) \, \mathtt{malloc} \, (\, \mathtt{sizeof} \, (\mathbf{double}) \, * \mathtt{k}) \quad ;
         double *old centroids = (double*) malloc(sizeof(double)*k);
         int *num data per cluster = (int*) malloc(sizeof(long)*k);
         double *total data per cluster = (double*) malloc(size of (double)*k);
```

```
//calcolo del minimo e del massimo
for(i=1;i < array length; i++) {
         if (array [i] > max)
                  \max = \operatorname{array}[i];
         i\,f\,(\,\text{array}\,[\,\,i\,\,]\,\,<\,\,\min\,)
                  min = array[i];
printf("k %d:\n", k);
//assegnazione\ dei\ primi\ due\ centroidi
centroids[0] = min;
\verb|printf("centroide min %lf\n", centroids[0]);|\\
c\,e\,n\,t\,r\,o\,i\,d\,s\,\left[\,\,k\,-\,1\,\right] \,\,=\,\, \max\,;
printf\left(\texttt{"centroide max \%lf\n"}\,,\ centroids\left[\,k-1\,\right]\right);
//calcolo degli altri centroidi in caso k>2
/***
if(k>2) {
         for(i=1; i < k-1; i++) {
                  centroids[i] = min + i*(max-min)/k;
                  printf("new %lf | n", centroids[i]);
for(i=0; i < k; i++)
printf("centroide[%d] = %lf|n", i, centroids[i]);
************************************
///PROVA CLUSTER RANDOM
for (i = 1; i < k-1; i++)
{
         int rand = csim random int(0, array length);
         centroids[i] = array[rand];
/*** FINE PROVA CLUSTER RANDOM*/
while (! iter) {
         //assegnazione\ dei\ dati\ ad\ ogni\ cluster
         for (i=0; i < array length; i++) {
                  distance = fabs(centroids[0] - array[i]);
                  for (j=1; j < k; j++) {
                            distance temp = fabs(centroids[j]-array[i]);
                            if(distance > distance\_temp) {
                                     distance = distance_temp;
                                     counter = j;
                                     //printf("counter: %d | n", counter);
                            }
```

```
}
                           num data per cluster[counter] += 1;
                           total\_data\_per\_cluster\,[\,counter\,] \,\,+\!\!=\,\, array\,[\,i\,]\,;
                           {\rm distance} \ = \ 0.0 \, ;
                           j = 0;
                           counter = 0;
                  //step per tenere memoria dell'iterazione precedente
                  for (i = 0; i < k; i++) {
                           old centroids[i] = centroids[i];
                  }
                  printf("\n");
                  //aggiornamento dei centroidi in seguito al primo step e
                      confronto con la precedente iterazione
                  {f for}\;(\;i=0\;;\;\;i\;<\;k\;;\;\;i++)\;\;\{
                           centroids\,[\,i\,] \ = \ total\_data\_per\_cluster\,[\,i\,] \ / \ ((\,double)
                               num_data_per_cluster[i]);
                           printf("i: %d, centroide: %lf - tot_dati: %d\t", i,
                                 centroids[i], num_data_per_cluster[i]);
                           if( fabs(centroids[i]-old centroids[i]) < pow</pre>
                                (10,-10) ) { //valore\ epsilon\ = 10^-10
                                    printf("converged: %d\n", converged);
                                    converged++;
                           }
                  // controllo se l'algoritmo converge
                  if(converged == k) {
                           iter = 1;
                  }
                  converged = 0;
                  memset(num data per cluster, 0, k*sizeof(double));
                  memset(total data per cluster, 0, k*sizeof(double));
         }
}
// Simulazione \ per \ la \ generazione \ dei \ cluster \ di \ documenti.
void sim(int argc, char **argv)
{
         //creazione e reseeding degli stream
         sess req 1 = create stream();
         {\tt reseed (sess\_req\_1 \ , \ SEED)} \ ;
         sess_req_2 = create_stream();
         reseed (sess_req_2 , SEED);
         user_tt = create_stream();
         reseed (user tt , SEED);
```

```
object req = create stream();
{\tt reseed}\;(\,o\,bj\,ect\,\_\,re\,q\;,\;\;SEED)\;;
html 1 = create stream();
reseed(html_1, SEED);
html\_2 = create\_stream();
reseed (html 2, SEED);
obj size = create stream();
reseed(obj size, SEED);
create("prova");
int array length= 10000000;
\mathbf{double} \ * \mathtt{array} \ = \ (\mathbf{double}*) \ \mathtt{malloc} \ (\ \mathtt{sizeof} \ (\mathbf{double}) * \mathtt{array\_length} \ ) \ ;
double session;
int objects;
int i=0;
int j = 0;
int k=0:
//generazione delle sessioni e delle relative richieste
while(i < array length) {</pre>
          session = session_request(mu_session, lambda_session);
          for(j=0; j < session; j++) {
                   if(i < array_length) {
                             array[i] = html_page_size(mu_html,
                                 sigma html, alfa html);
                   }
                   i++;
                   objects = object_per_request(alfa_obj);
                   for (k=0; k<0 \, bj \, ect \, s; k++){}
                             if(i<array length)</pre>
                                      array[i] = embedded_object_size(
                                           mu emb, sigma emb);
                             i++;
                   }
         }
//clustering dei documenti
cluster(array, array_length,5);
int m=0;
/*FILE *fd file;
char *pathname = (char*)malloc(128);
sprintf(pathname, "docs");
fd\_file = fopen(pathname, "w");
for(m=0;m< array\_length;m++) {
         fp \ rin \ tf \ (fd \_file \ , \ "\%g \ | \ n " \ , \ array \ [m]) \ ;
fclose (fd file);
```

CAPITOLO 6. APPENDICE

*/

}

6.3 gaussiana inversa.c

```
#include "gaussiana_inversa.h"
//dichiarazione degli stream
STREAM sess req 1;
STREAM sess req 2;
STREAM user tt;
STREAM object_req;
STREAM html 1;
STREAM html 2;
STREAM obj_size;
STREAM p_hit_proxy;
//calcolo della media per una distribuzione lognormale
double calc mean lognormal(double mu, double sigma)
{
        double sum = mu+(pow(sigma, 2)/2);
        return exp(sum);
}
//calcolo della deviazione standard per una distribuzione lognormale
double calc stddev lognormal(double mu, double sigma)
{
        double sum = (\exp(pow(sigma, 2)) - 1) * \exp(2*mu + pow(sigma, 2));
        return sqrt(sum);
}
//algoritmo di Michael/Schucany/Haas per la generazione di valori tramite la
     gaussiana inversa
int session request (double mu, double lambda) //dimensionare come un
    intero???
{
        double v = stream_normal(sess_req_1, 0, 1);
        double y = pow(v, 2);
        \textbf{double} \ x1 = 0;
        x1 = mu + ((pow(mu, 2)*y)/(2*lambda)) - ((mu/(2*lambda)) * sqrt(4*mu*)
            lambda*y+pow(mu,2)*pow(y,2));
        double u = stream uniform(sess req_2, 0, 1);
        double temp = mu/(mu+x1);
        if(u <= temp) {
                x = (int) round(x1);
        }
        else
                x = (int) round(pow(mu,2)/x1);
```

```
return x;
}
//generazione di valori per il think time dell'utente (Pareto)
double user\_think\_time(double alfa)
{
         double x = 0.0;
         \mathbf{while}(\mathbf{x} < 1) {
                 x = stream_pareto(user_tt, alfa);
         return x;
}
//generazione del numero di oggetti per richiesta (Pareto)
int object per request(double alfa)
         int x = 0;
         \mathbf{while}(x < 2) {
                  x = (int)round(stream pareto(object req, alfa));
         return x;
}
//generazione della dimensione della pagina html (Pareto e Lognormale)
double html_page_size(double mu, double sigma, double alfa)
         double x = 0.0;
         int k = 10240; //dimensionarlo in KB???
         x = stream lognormal(html 1, calc mean lognormal(mu, sigma),
             calc_stddev_lognormal(mu, sigma));
         if (x<k)
                  return x;
         else {
                  x = stream pareto(html 2, alfa);
                  \mathbf{while}(x < k) {
                           x = stream\_pareto(html_2, alfa);
                  }
         }
         \textbf{return} \ x \ ;
}
//generazione della dimensione degli embedded object (Lognormale)
\mathbf{double} \ \mathtt{embedded\_object\_size} \\ (\mathbf{double} \ \mathtt{mu}, \ \mathbf{double} \ \mathtt{sigma})
{
         double x = 0.0;
         while (x \le 0.0) {
```

6.4 service.c

```
#include "service.h"
 st In questo file sono contenute tutte le domande di servizio per i
      componenti della rete.
 * Le domande di servizio delle schede di rete LS2, LW2 e LW3 non sono state
       implementate
 * poiche' si e' assunto che queste presentino un transfer rate pari alla
      banda delle LAN a
 * \quad cui \quad sono \quad collegate \; .
 */
// Divide il numero di Byte m in ingresso in datagrammi
int NDatagrams(double m) {
          int n;
          double f;
          f=m/(double)MSS;
                                      //MSS in Byte
          n = (int) ceil(f);
          return n;
}
// Calcola l'overhead della connessione TCP/IP e del livello DataLink
int Overhead(double m) {
          return (NDatagrams(m)*(TCPOV+IPOV+FRAMEOV)); //[Byte]
}
// Calcola il numero di blocchi da leggere per un documento
int number of blocks(double docSize) {
          return ceil(docSize/BLOCK SIZE);
}
 * Calcola il tempo necessario per trasferire m Byte (sec)
 *\ m\ in\ byte\ ,\ bandwidth\ in\ bit
double NetworkTime(double m, double bandwidth) {
          return (double)(8*(m+Overhead(m)))/(double)(1000*1000*bandwidth); //
               [sec]
}
//\ Domanda\ di\ servizio\ (sec)\ per\ l\ 'incoming\ link
double D_InLink() {
          \textbf{return} \hspace{0.2cm} \texttt{NetworkTime}(\texttt{AVG} \hspace{0.2cm} \texttt{SIZE} \hspace{0.2cm} \texttt{HTTP} \hspace{0.2cm} \texttt{REQ}, \hspace{0.2cm} \texttt{INLINK} \hspace{0.2cm} \texttt{BANDWIDTH}) \hspace{0.2cm} + \hspace{0.2cm} 3 \hspace{0.2cm} *
               NetworkTime(0.0001, INLINK BANDWIDTH);
}
```

```
//domanda\ di\ servizio\ per\ l'outgoing link
double D OutLink(double docSize) {
        \textbf{return} \hspace{0.2cm} \textbf{NetworkTime(docSize, OUTLINK BANDWIDTH)} \hspace{0.2cm} + \hspace{0.2cm} 2 \hspace{0.2cm} * \hspace{0.2cm} \textbf{NetworkTime}
             (0.0001, OUTLINK BANDWIDTH);
}
 * Calcola la domanda di servizio sottomessa alla LAN che collega il Web
     Switch con i Web Server.
.* Il fattore moltiplicativo 1024 e' commentato perche' le richieste sono
    gia , espressi in byte
double D LAN(double docSize) {
        if(docSize == 0) {
                  return NetworkTime(AVG SIZE HTTP REQ, BANDWIDTH L2);
        }
        return NetworkTime(/*1024 **/ docSize, BANDWIDTH L2);
}
// Calcola la domanda di servizio sottomessa ad una CPU (sia Web Switch che
    web server) (sec),
double D Cpu(double speed) {
        return 1 / speed;
// Calcola la domanda di servizio sottomessa ad un disco del Web Server (sec
    )
double D WSDisk(double doc size) {
        double ret = (number of blocks(doc size)) * ((DISK SEEK TIME/pow
             (10\,,3\,)\,)\,\,+\,\,ROTATIONAL\_LATENCY\,\,+\,\,(CONTROLLER\_TIME/pow\,(10\,,3\,)\,)\,\,+\,\,(10\,,3\,)
             BLOCK SIZE/((double)DISK TRANSFER RATE*pow(10,6)));
        return ret;
}
//calcola la domanda di servizio del link addizionale
double D linkAdd(double doc size) {
        return NetworkTime(doc size, BANDWIDTH LINKADD) + 2 * NetworkTime
             (0.0001, BANDWIDTH LINKADD);
//calcola la domanda di servizio in entrata della scheda di rete LS1
double D LS1in()
{
```

6.5 client.c

```
#include "client.h"
double mu_session = 3.86;
double lambda session = 9.46;
double alfa_tt = 1.4;
double alfa obj = 1.33;
double mu html = 7.63;
double sigma_html = 1.001;
\mathbf{double} \ \ \mathbf{alfa\_html} \ = \ 1 \, ;
double mu_emb = 8.215;
double sigma emb = 1.46;
extern FACILITY cpuWS[NUM_SERVER];
extern FACILITY diskWS[NUM DISK*NUM SERVER];
extern BOX WebServer;
extern BOX WebSwitch;
extern FACILITY L2;
extern FACILITY CPU_web_switch;
extern FACILITY inLink;
extern FACILITY outLink;
extern FACILITY link add;
extern FACILITY LS1;
extern FACILITY LS2;
extern FACILITY LW2[NUM SERVER];
extern FACILITY LW3[NUM_SERVER];
extern TABLE rtime;
extern METER lambda;
extern CLASS requestClasses[K];
extern STREAM p hit proxy;
int currentDisk[NUM SERVER];
int num_osservazioni;
int current_server;
double **observations;
int observed sample;
int maxObservation;
double client_response_time;
// Ritorna l'indice del server meno utilizzato (serve per la least loaded)
int get_least_loaded()
{
        \quad \textbf{int} \quad i=0\,;
        int j=0;
```

```
double disk qlen = 0.0;
          \mathbf{double} \ \mathtt{server\_qlen} \ = \ 0.0 \, ;
          double qlen tmp = 0.0;
          int index = 0;
          \quad \textbf{for} \; (\; i=0 \; ; \quad i \; < \; \text{NUM DISK} \; ; \quad i++)
                    disk qlen += qlength(diskWS[i]);
          server qlen = qlength (cpuWS[0])+disk qlen+qlength (LW2[0]);
          for (i=1; i \le NUM SERVER; i++) {
                    disk_qlen = 0.0;
                     for (j=0; j < NUM DISK; j++) {
                               \label{eq:disk_qlen} \begin{array}{ll} \operatorname{disk} \_ \operatorname{qlen} \ + = \ \operatorname{qlength} \left( \operatorname{diskWS} \left[ \ j + i * \operatorname{NUM\_DISK} \right] \right) \ ; \ \ / / \ i * \end{array}
                                    NUM\_DISK perche' per ogni server ci sono
                                    NUM \ DISK \ dischi
                    qlen tmp = disk qlen+qlength(cpuWS[i])+qlength(LW2[i]);
                    if(server qlen > qlen tmp) {
                              server_qlen = qlen_tmp;
                               index = i;
                    }
                    qlen tmp = 0.0;
          return index;
}
// \,Gestisce \quad l \ \ 'intero \quad flusso \quad richiesta-risposta
int web_client(double doc_size, int variant, int bool_transient, int iter)
{
          double start Time;
          \label{eq:double_server_start_time} \ = \ 0.0;
          double switch start time = 0.0;
          int tmp server;
          startTime = simtime();
          int tmp disk = 0;
          //vedi pag. 131 user guide
          note_passage(lambda);
          use(inLink, D InLink());
          switch start time = enter box(WebSwitch);
          use(LS1, D LS1in());
          use(CPU web switch, D Cpu(CPU WEB SWITCH SERVICE RATE));
  use(LS2, D LAN(0)); //stessa banda della LAN, in richiesta doc size=0
  exit_box(WebSwitch, switch_start_time);
          use(L2, D LAN(0));
```

```
/* random */
if(variant == RANDOM || variant == LINK ADD || variant == PROXY) {
         tmp server = current server;
         {\tt current\_server} = {\tt csim\_random\_int} \, ({\tt 0} \, , \, \, {\tt NUM\_SERVER-1}) \, ;
}
else if (variant == ROUND ROBIN) { //round robin
         tmp server = current server;
         current server = (tmp server+1)%NUM SERVER;
// least loaded
else if (variant == LEAST LOADED) {
         tmp\_server = get\_least\_loaded();
server start time = enter box (WebServer);
use(LW2[tmp server], D LAN(0));
use(cpuWS[tmp server], D Cpu(CPU SERVICE RATE));
//selezione del disco round robin
tmp disk = current Disk [tmp server];
\verb|currentDisk[tmp_server|| = (tmp_disk+1)\%NUM_DISK;|
use(diskWS[tmp server*NUM DISK + tmp disk], D WSDisk(doc size));
use(cpuWS[tmp server], D Cpu(CPU SERVICE RATE));
if(variant != LINK ADD) {
         use(LW2[tmp server], D LAN(doc size));
}
\mathbf{else} \ \{
         use(LW3[tmp server], D linkAdd(doc size));
exit box (WebServer, server start time);
if(variant == LINK ADD) {
         use(link_add, D_linkAdd(doc_size));
}
else {
         use(L2, D_LAN(doc_size));
         use(LS2, D LAN(doc size));
         use\left( \texttt{CPU\_web\_switch} \right., \ \ D\_\texttt{Cpu}(\texttt{CPU\_WEB\_SWITCH\_SERVICE\_RATE}) \left. \right);
         use(LS1, D LS1out(doc size));
         use(outLink, D OutLink(doc size));
}
client\_response\_time \ = \ simtime \, () - start \, Time \, ;
tabulate (rtime, simtime ()-start Time);
\verb"num_osservazion" i++;
```

```
//utilizzato per il transiente per tener conto del numero di
             o\,s\,s\,e\,r\,v\,a\,z\,i\,o\,n\,i
         if(bool transient == 1 && observed sample <= maxObservation) {</pre>
                  observations[iter][observed sample] = simtime()-startTime;
                  observed sample++;
        }
        return 0;
}
//Generazione di una sessione e delle relative richieste
{\bf void} \ \ {\bf web\_session(int} \ \ {\bf cli\_id} \ , \ \ {\bf int} \ \ {\bf variant} \ , \ \ {\bf int} \ \ {\bf bool\_transient} \ , \ \ {\bf int} \ \ {\bf iter)
        char *prova = (char*) malloc(64); //il nome del processo
         sprintf(prova, "%d", cli id);
         create (prova);
        double html page, emb obj size;
        int num embedded objects;
        int session = session request(mu session, lambda session);
        int i = 0;
        int j = 0;
         for(i=0; i < session; i++) {
                  html page = html page size(mu html, sigma html, alfa html);
                  set_process_class(requestClasses[get_doc_class(html_page)]);
                  if(variant == PROXY \&\& stream_prob(p_hit_proxy) > 0.4)  {
                           web_client(html_page, variant, bool_transient, iter)
                  if(variant != PROXY) {
                           web client (html page, variant, bool transient, iter)
                  }
                  num embedded objects = object per request(alfa obj);
                  for(j=0; j < num embedded objects; j++) {
                           \verb|emb_obj_size| = \verb|embedded_object_size| (mu_emb,
                               sigma_emb);
                           set_process_class(requestClasses[get_doc_class(
                               emb obj size)]);
                           if(variant == PROXY && stream prob(p hit proxy) >
                               0.4) {
                                    web client (emb obj size, variant,
                                        bool transient, iter);
                           if(variant != PROXY) {
                                    web_client(emb_obj_size, variant,
                                         bool transient, iter);
```

```
}
                     }
                     hold(user_think_time(alfa tt));
          }
          csim terminate();
}
//assegna una classe ad un documento, sulla base delle distanze da i
\mathbf{int} \ \mathtt{get\_doc\_class}(\mathbf{double} \ \mathtt{doc\_size})
{
          double distance [K];
          int i = 0;
          double min;
          int index = 0;
          \operatorname{distance}[0] = \operatorname{fabs}(10281 - \operatorname{doc}_{-\operatorname{size}});
          distance[1] = fabs(279513744 - doc size);
          distance[2] = fabs(715827882 - doc\_size);
          /* distance[0] = fabs(10073 - doc size);
          distance[1] = fabs(17740962 - doc_size);
          distance[2] = fabs(70926601 - doc_size);
          distance[3] = fabs(279513744 - doc size);
          distance[4] = fabs(715827882 - doc_size);
          min = distance[0];
          \label{eq:for} \textbf{for} \; (\; i = 1 \; ; \; \; i \; < \; K \; ; \; \; i + +) \; \; \{
                     if(distance[i] < min) {</pre>
                               min = distance[i];
                               index = i;
                     }
          return index;
}
```

6.6 transient.c

```
\#include < stdio.h >
\#include < stdlib.h>
\#i\,n\,c\,l\,u\,d\,e\,{<}\,s\,t\,\,r\,i\,n\,g . 
 h>
\#include < csim.h >
#include "gaussiana_inversa.h"
#include "client.h"
#include "common.h"
extern FACILITY cpuWS[NUM SERVER];
extern FACILITY diskWS[NUM_DISK*NUM_SERVER];
extern BOX WebServer;
extern BOX WebSwitch;
extern FACILITY L2;
extern FACILITY CPU web switch;
extern FACILITY inLink;
extern FACILITY outLink;
extern FACILITY link add;
{\tt extern \ FACILITY \ LS1;}
extern FACILITY LS2;
extern FACILITY LW2[NUM SERVER];
extern TABLE rtime;
extern METER lambda;
extern CLASS request Classes [K];
extern STREAM sess_req_1;
extern STREAM sess_req_2;
extern STREAM user tt;
extern STREAM object req;
extern STREAM html 1;
extern STREAM html 2;
extern STREAM obj size;
extern STREAM p hit proxy;
extern double client_response_time;
extern double **observations;
extern int observed sample;
extern int maxObservation;
TABLE resptime;
\label{eq:matrix} \textbf{int} \ \ WELCH \ \ N = \ 0 \ , \ \ WELCH \ \ W = \ 0 \ ;
char * output_file_name;
//Parsa i parametri passati da linea di comando
```

```
void parse command line(int argc, char *argv[]) {
           if (argc != 5) {
                      p\,r\,i\,n\,t\,f\,\left(\,\hbox{\tt\tt'ERRORE}\,!\,!\,!\,\backslash\,\hbox{\tt\tt nUtilizzo}\,\colon\,\,\,\hbox{\tt\tt''}\,\right)\,;
                      p \, r \, in \, t \, f \, (\, \hbox{\tt "./transient < WELCH_N > < WELCH_M > < WELCH_W > < } \, \\
                           file_output > \n");
                      exit(1);
           }
          WELCH\_N = atoi(argv[1]);
          WELCH M = atoi(argv[2]);
          W\!E\!L\!C\!H\_W = \ atoi\left(\,a\,r\,g\,v\,\left[\,3\,\right]\,\right)\,;
           output_file_name = argv [4];
           i\,f\,(\text{WELCH\_W}\,>\,\text{WELCH\_M}/\,2\,)\,\{
                      printf("ERRORE!!!\nIl valore della finestra W deve essere
                           minore della parte intera di M/2.\n\n");
                      exit(1);
           }
           return;
}
//Simulazione del transiente
void sim(int argc, char *argv[]){
\mathbf{int} client ID = 0,
            cont = 0,
            i , s ,
            n repl=0,
            m_repl=0;
            parse_command_line(argc, argv);
double intT,
                       *averaged\_process,
                       sum = 0.0,
                       *moving average;
FILE * mov_avg_fd;
           maxObservation = WELCH M;
           observed\_sample = 1;
           create("sim");
```

```
max processes (MAX PROCESSES); //numero massimo dei processi in
    giro nella rete
max facilities (MAX FACILITIES);
max servers (MAX SERVERS);
inLink = facility("inLink");
outLink = facility ("outLink");
LS1 = facility("LS1");
LS2 = facility ("LS2");
CPU web switch = facility("CPU_web_switch");
L2 = facility("L2");
facility set (cpuWS, "cpuWS", NUM SERVER);
\label{eq:continuous} \mbox{facility\_set} \ (\mbox{diskWS} \ , \ \ "\mbox{diskWS"} \ , \ \mbox{NUM\_SERVER*NUM\_DISK}) \ ;
\label{eq:continuous} {\tt facility\_set} \; (LW2, \;\; \verb"LW2", \;\; NUM\_SERVER) \; ;
resptime = table("System Response Time"); // table intialization
char className[20];
WebSwitch = box("Web Switch");
WebServer = box("Web Server");
lambda = meter("Arrival Rate");
max classes (MAX CLASSES);
                                 //viene assegnato il numero massimo
    di classi per evitare l'errore "TOO MANY PROCESSES CLASS"
for(cont = 0; cont < NUM CLASSES; cont ++) {
         className[0] = '\0';
         sprintf(className, "Classe%d", cont);
         requestClasses[cont] = process class(className);
// \ Inizializzazione \ degli \ stream \ (reseed \ simtime*i+num)
sess req 1 = create stream();
reseed(sess\_req\_1, (int)simtime()+i+1);
sess req 2 = create stream();
reseed (sess req 2, (int) simtime()*2+i+1);
user_tt = create_stream();
reseed (user tt, (int) simtime () *3+ i+1);
object req = create stream();
reseed (object req, (int) simtime()*4+i+1);
html 1 = create stream();
\verb|reseed| (\verb|html_1|, | (\verb|int|) simtime| ()*5+i+1);
html 2 = create stream();
reseed (html 2, (int) simtime()*6+i+1);
obj size = create stream();
reseed (obj size, (int) simtime() *7+i+1);
p_hit_proxy = create_stream();
reseed (p_hit_proxy, (int) simtime()*8+i+1);
collect_class_facility_all();
```

```
rtime=table("Response Time");
averaged process = malloc((WELCH M +1)*sizeof(double));
moving average=malloc((WELCH M - WELCH W + 1)*sizeof(double));
observations = (double**) malloc (WELCH N * size of (double*));
for ( i = 0; i < WELCH N; i + +){
         observations[i] = (double*) malloc(WELCH M * sizeof(double));
}
//PASSO 1: vengono effettuate WELCH N repliche di lunghezza WELCH M
    ognuna. I risultati
                             sono\ inseriti\ nella\ matrice\ sample\ matrix\,.
//
                    Il tempo di risposta percepito dal client viene
    campionato\ ogni\ SAMPLE\ TIME\ secondi
               Il generatore di numeri casuali non viene mai azzerato
//ciclo di generazione delle richieste
printf("n_repl =%d, m_repl =%d\n", n_repl, m_repl);
while(n repl < WELCH N) {
         observed sample = 1;
         while(observed_sample < WELCH M) {
                  intT=exponential(1/(double)(ARRIVAL));
                  hold (intT);
                                             //think time
                  web session(clientID, RANDOM, 1, n repl);
                  clientID++;
         p \, rin \, t \, f \, (\, \hbox{\tt "Replication n \%d terminated \ \ "} \, , \, n \, \underline{\hspace{0.5cm}} \, rep \, l \, ) \, ;
         //ogni volta che viene terminata una replica e' necessario
         //riavviare le risorse
         wait (event list empty);
         reset();
         reseed (sess req 1, (int) simtime ()+i+1);
         \verb|reseed (sess_req_2|, | (\verb|int|) simtime () *2 + i + 1);
         reseed (user tt, (int) simtime()*3+i+1);
         reseed (object\_req, (int) simtime()*4+i+1);
         reseed (html 1, (int) simtime() *5+i+1);
         reseed (html 2, (int) simtime()*6+i+1);
         reseed (obj size, (int) simtime() *7+i+1);
         reseed (p hit proxy, (int) simtime()*8+i+1);
         n_repl++;
}
```

```
//PASSO 2: Viene riempito l'array averaged process con la media
    ottenuta dividendo
//per WELCH N, ovvero il numero di repliche effettuate, la somma di
    tutte le repliche
//per un dato indice appartenente all'insieme WELCH\_M
for(m repl = 0; m repl < WELCH M; m repl++){
        for(n repl=0; n repl<WELCH N; n repl++) {
          sum \ += \ observations [\, n\_repl\, ] \, [\, m\_repl\, ] \, ;
        averaged process[m repl+1] = sum/(double)WELCH N;
        sum = 0.0;
}
        //PASSO 3: Calcolo dell'array Moving Average
\mathbf{for} (i = 1; i \le (WELCH M - WELCH W); i++){
        sum = 0.0;
        if(i \le WELCH W){
                 for (s = -(i-1); s \le (i-1); s++)
                         sum = sum + averaged process[i+s];
                 moving average [i] = sum/(double)(2*i - 1);
        }
        else{
                 for (s = -WEICH W; s \le WEICH W; s++)
                         sum = sum + averaged process[i+s];
                 moving average[i] = sum/(double)(2*WELCH W + 1);
        }
}
//PASSO 4: scrittura dell'array moving average su file che sara'
    utile poi per graficare
           i valori e determinare il valore l (lunghezza del
    transiente).
mov_avg_fd = fopen(output_file_name, "w");
```

6.7 main.c

```
#include < stdlib.h>
#include < stdio.h>
#include <csim.h>
#include "client.h"
#include "common.h"
#include "gaussiana_inversa.h"
#include "service.h"
\#ifndef\_ISOC99\_SOURCE
\#define _ISOC99_SOURCE
\#e\,n\,d\,i\,f
extern STREAM sess req 1;
extern STREAM sess req 2;
extern STREAM user tt;
extern STREAM object req;
extern STREAM html 1;
extern STREAM html_2;
extern STREAM obj size;
extern STREAM p_hit_proxy;
extern FACILITY cpuWS[NUM SERVER];
extern FACILITY diskWS[NUM DISK*NUM SERVER];
extern BOX WebServer;
extern BOX WebSwitch;
extern FACILITY L2;
extern FACILITY CPU web switch;
extern FACILITY inLink;
extern FACILITY outLink;
extern FACILITY link add;
extern FACILITY LS1;
extern FACILITY LS2;
extern FACILITY LW2[NUM SERVER];
extern FACILITY LW3[NUM SERVER];
extern TABLE rtime;
extern METER lambda;
//decidere quante classi fare sulla base del clustering
extern CLASS request Classes [K];
extern int num osservazioni;
TABLE resptime;
double lambda tmp;
double utilizzazione L2 [NUM CLASSES], utilizzazione inLink [NUM CLASSES],
    utilizzazione outLink[NUM CLASSES],
```

```
utilizzazione cpu web switch [NUM CLASSES], utilizzazione cpu web server [
   NUM CLASSES], utilizzazione disk[NUM CLASSES], utilizzazione link add[
    NUM CLASSES], utilizzazione ls1 [NUM CLASSES], utilizzazione ls2 [
   NUM CLASSES], utilizzazione lw2 [NUM CLASSES], utilizzazione lw3 [
    NUM CLASSES ];
double qlen L2 [NUM CLASSES], qlen inLink [NUM CLASSES], qlen outLink [
   NUM CLASSES], qlen cpu web switch[NUM CLASSES],
qlen cpu web server [NUM CLASSES], qlen disk [NUM CLASSES], qlen link add [
   NUM CLASSES], qlen ls1 [NUM CLASSES], qlen ls2 [NUM CLASSES], qlen lw2 [
    NUM CLASSES], qlen lw3[NUM CLASSES];
double rtime L2 [NUM CLASSES], rtime inLink [NUM CLASSES], rtime outLink [
    \label{local_num_classes} \mbox{NUM\_CLASSES]} \;, \; \; \mbox{rtime\_cpu\_web\_switch} \left[ \mbox{NUM\_CLASSES} \right] \;,
rtime_cpu_web_server[NUM_CLASSES], rtime_disk[NUM_CLASSES], rtime_link_add[
    NUM CLASSES], rtime ls1 [NUM CLASSES], rtime ls2 [NUM CLASSES], rtime lw2 [
    NUM CLASSES], rtime lw3[NUM CLASSES];
double tot temp;
// Calcolo delle statistiche per ogni componente: utilizzazione, lunghezza
    delle code e tempo di risposta
void print tot(FILE *fd)
{
        fprintf(fd, "&%.7f\\\\n\\hline", tot temp);
        tot temp = 0;
}
void statistics(int iteration, int variant) {
        lambda_tmp += meter_rate(lambda);
        int i = 0;
        int j = 0;
        for (; i < NUM CLASSES; i++) {
                  utilizzazione L2[i] += class util(L2, requestClasses[i]);
                  qlen L2[i] += class qlen(L2, requestClasses[i]);
                 rtime L2[i] += class resp(L2, requestClasses[i]);
                  utilizzazione\_inLink\left[\:i\:\right] \;+=\; class\_util\left(inLink\:,\; requestClasses\:\right.
                      [i]);
                  glen inLink[i] += class glen(inLink, requestClasses[i]);
                  rtime inLink[i] += class resp(inLink, requestClasses[i]);
                  utilizzazione\_outLink\left[\ i\ \right]\ +=\ class\_util\left(\ outLink\ ,\right.
                      request Classes [i]);
                  qlen outLink[i] += class qlen(outLink, requestClasses[i]);
                  rtime_outLink[i] += class_resp(outLink, requestClasses[i]);
```

```
utilizzazione cpu web switch[i] += class util(CPU web switch
            , request Classes [i]);
        qlen cpu web switch[i] += class qlen(CPU web switch,
            request Classes [i]);
        rtime\_cpu\_web\_switch [i] \ += \ class\_resp (CPU\_web\_switch \,,
            request Classes [i]);
        utilizzazione ls1[i] += class util(LS1, requestClasses[i]);
        qlen ls1[i] += class qlen(LS1, requestClasses[i]);
        rtime_ls1[i] += class_resp(LS1, requestClasses[i]);
        utilizzazione_ls2[i] += class_util(LS2, requestClasses[i]);
        qlen ls2[i] += class qlen(LS2, requestClasses[i]);
        rtime ls2[i] += class resp(LS2, requestClasses[i]);
        if (variant == LINK ADD) {
                utilizzazione_link_add[i] += class_util(link_add,
                     requestClasses[i]);
                qlen_link_add[i] += class_qlen(link_add,
                     requestClasses[i]);
                rtime link add[i] += class resp(link add,
                     requestClasses[i]);
        }
}
double util cpu tmp[NUM CLASSES] = \{0.0\};
double qLen_cpu_tmp[NUM_CLASSES] = \{0.0\};
double rtime cpu tmp[NUM CLASSES] = \{0.0\};
double util disk tmp[NUM CLASSES] = {0.0};
double qLen disk tmp[NUM CLASSES] = {0.0};
double rtime disk tmp[NUM CLASSES] = \{0.0\};
double util lw2 tmp[NUM CLASSES] = \{0.0\};
double qLen lw2 tmp[NUM CLASSES] = {0.0};
double rtime lw2 tmp[NUM CLASSES] = \{0.0\};
double util lw3 tmp[NUM CLASSES] = \{0.0\};
double qLen lw3 tmp[NUM CLASSES] = \{0.0\};
double rtime lw3 tmp[NUM CLASSES] = {0.0};
// Per ogni classe colleziono le statistiche di interesse (mediate
    sul numero dei server e dei dischi)
for (j=0; j < NUM CLASSES; j++) {
```

```
//calcolo metriche cpu web server
for (i=0; i < NUM SERVER; i++){
           util_cpu_tmp[j] += class_util(cpuWS[i],
                requestClasses[j]);
           qLen\_cpu\_tmp\left[\;j\;\right] \;\; += \;\; c\,l\,a\,s\,s\,\_\,q\,l\,e\,n\,\left(\;cpuWS\left[\;i\;\right]\;,
                 requestClasses[j]);
           rtime\_cpu\_tmp\left[\ j\ \right]\ +=\ class\_resp\left(cpuWS\left[\ i\ \right]\ ,
                requestClasses[j]);
           util_lw2_tmp[j] += class_util(LW2[i], requestClasses
                 [j]);
           qLen\_lw2\_tmp\left[\;j\;\right] \;\; += \;\; class\_qlen\left(LW2\left[\;i\;\right], \;\; request\,Classes
                [j]);
           rtime\_lw2\_tmp\left[\ j\ \right]\ +=\ class\_resp\left(LW2\left[\ i\ \right]\ ,
                 requestClasses[j]);
           if(variant == LINK ADD)  {
                      util\_lw3\_tmp[j] \ += \ class\_util(LW3[i]),
                            request Classes [j]);
                      qLen_lw3\_tmp[j] \ += \ class\_qlen(LW3[i]),
                            request Classes [j]);
                      rtime\_lw3\_tmp[j] \ += \ class\_resp(LW3[i]),
                            request Classes [j]);
           }
}
utilizzazione cpu web server[j] += util cpu tmp[j]/(double)
     NUM SERVER;
\label{eq:cpu_web_server} \footnotesize \left[ \; j \; \right] \; + = \; \footnotesize \left[ \; \text{pu_tmp} \left[ \; j \; \right] \; / \left( \; \textbf{double} \right) \\ \footnotesize \text{NUM\_SERVER} \; \right.
rtime_cpu_web_server[j] += rtime_cpu_tmp[j]/(double)
     NUM SERVER;
utilizzazione_lw2[j] += util_lw2_tmp[j]/(double)NUM_SERVER;
qlen lw2[j] += qLen lw2 tmp[j]/(double)NUM SERVER;
rtime_lw2[j] += rtime_lw2_tmp[j]/(double)NUM_SERVER;
if(variant == LINK ADD) {
           utilizzazione_lw3[j] += util_lw3_tmp[j]/(double)
                NUM SERVER;
           qlen lw3[j] += qLen lw3 tmp[j]/(double)NUM SERVER;
           rtime lw3[j] += rtime lw3 tmp[j]/(double)NUM SERVER;
}
// calcolo metriche disco
\label{eq:for_server_sum_disk} \textbf{for} \; (\; i = 0 \, ; \quad i < (NUM\_SERVER*NUM\_DISK) \; ; \quad i + +) \{
           util_disk_tmp[j] += class_util(diskWS[i],
                requestClasses[j]);
           qLen\_disk\_tmp\left[\;j\;\right] \;+\!\!=\; class\_qlen\left(\;diskWS\left[\;i\;\right]\;,
                 requestClasses[j]);
```

```
rtime disk tmp[j] += class resp(diskWS[i],
                       requestClasses[j]);
         }
         utilizzazione\_disk[j] += util\_disk\_tmp[j]/(double)(
             NUM SERVER*NUM DISK);
         qlen disk[j] += qLen disk tmp[j]/(double)(NUM SERVER*
             NUM DISK);
         rtime disk[j] += rtime disk tmp[j]/(double)(NUM SERVER*
             NUM DISK);
}
FILE *fd file;
char *pathname = "util_qlen_rtime";
//Stampa dei risultati su file
if(iteration==NUM ITERATIONS-1) {
         fd_file = fopen(pathname, "w");
         fprintf(fd\_file, "\hline\nUtilizzazioni\n\hline\n");
         fprintf(fd-file\;,\;"\texttt{Centro}\;\&\texttt{Classe1}\;\&\texttt{Classe2}\;\&\texttt{Classe3}\;\&\texttt{Totale}
              fprintf(fd file, "\n cpu web server i-esimo: \t");
         \label{eq:for_state} \textbf{for} \; (\; j = 0 \; ; \; \; j < \hspace{-0.1cm} \text{NUM\_CLASSES} \; ; \; \; j + \hspace{-0.1cm} + \hspace{-0.1cm} )
         {
                  fprintf(fd file, "&%.7f\t",
                       utilizzazione_cpu_web_server[j]/(NUM_ITERATIONS)
                  tot_temp += utilizzazione_cpu_web_server[j]/(
                       NUM ITERATIONS);
         print_tot(fd_file);
         fprintf(fd file, "\n disco i-esimo: \t");
         for (j=0; j \le NUM CLASSES; j++)
                  fprintf(fd_file, "&%.7f\t", utilizzazione_disk[j]/(
                       NUM ITERATIONS));
                  tot_temp += utilizzazione_disk[j]/(NUM_ITERATIONS);
         }
         print tot(fd file);
         fprintf(fd file, "\n inLink: \t");
         for (j=0; j < NUM CLASSES; j++)
         {
                  fprintf(fd\_file, "&%.7f\t", utilizzazione\_inLink[j]
                       ]/(NUM ITERATIONS));
                  tot\_temp \ += \ utilizzazione\_inLink[j]/(NUM\_ITERATIONS)
```

```
}
print tot(fd file);
fprintf(fd_file, "\n outLink: \t");
\quad \textbf{for} \; (\; j = 0 \; ; \; \; j < \text{NUM\_CLASSES} \; ; \; \; j + +)
{
         fprintf(fd file, "&%.7f\t", utilizzazione outLink[j
             ]/(NUM ITERATIONS));
        tot temp += utilizzazione outLink[j]/(NUM ITERATIONS
             );
print_tot(fd_file);
fprintf(fd file, "\n cpu web switch: \t");
for (j=0; j \le NUM CLASSES; j++)
         fprintf(fd file, "&%.7f\t",
             utilizzazione\_cpu\_web\_switch\ [\ j\ ]\ /\ (NUM\_ITERATIONS)
        tot_temp += utilizzazione_cpu_web_switch[j]/(
             NUM ITERATIONS);
print tot(fd file);
fprintf(fd_file, "\n LAN: \t");
for (j=0; j < NUM CLASSES; j++)
        fprintf(fd_file, "&%.7f\t", utilizzazione_L2[j]/(
            NUM ITERATIONS));
        tot_temp += utilizzazione_L2[j]/(NUM_ITERATIONS);
print tot(fd file);
fprintf(fd file, "\n LS1: \t");
for (j=0; j < NUM CLASSES; j++)
         fprintf(fd_file, "&%.7f\t", utilizzazione_ls1[j]/(
            NUM ITERATIONS));
        tot temp += utilizzazione ls1[j]/(NUM ITERATIONS);
print_tot(fd_file);
fprintf(fd_file, "\n LS2:\t");
for(j=0; j<NUM\_CLASSES; j++)
         fprintf(fd\_file\ ,\ \verb"&%.7f\t"\ ,\ utilizzazione\_ls2[j]/(
             NUM ITERATIONS));
```

```
tot temp += utilizzazione ls2[j]/(NUM ITERATIONS);
}
print tot(fd file);
fprintf(fd_file, "\n LW2: \t");
for (j=0; j \le NUM CLASSES; j++)
         fprintf(fd file, "%.7f\t", utilizzazione lw2[j]/(
             NUM ITERATIONS));
         tot_temp += utilizzazione_lw2[j]/(NUM_ITERATIONS);
print_tot(fd_file);
if(variant == LINK ADD) {
         fprintf(fd file, "\n LINK_ADD: \t");
         for (j=0; j<NUM CLASSES; j++)
         {
                  fprintf(fd_file, "&%.7f\t",
                       utilizzazione link add[j]/(
                      NUM_ITERATIONS));
                  tot temp += utilizzazione link add[j]/(
                      NUM ITERATIONS);
         }
  print tot(fd file);
         fprintf(fd file, "\n LW3: \t");
  \quad \quad \mathbf{for} \; (\; j = 0 \, ; \;\; j < \!\! \mathrm{NUM\_CLASSES} \, ; \;\; j + \!\! +)
                  fprintf(fd file, "&%.7f\t",
                       utilizzazione_lw3[j]/(NUM_ITERATIONS));
                  tot_temp += utilizzazione_lw3[j]/(
                      NUM ITERATIONS);
         print tot(fd file);
}
fp\,rintf\,(\,fd\,\_file\,\,,\,\,\,\hbox{\tt "\n\n\hline\nLunghezza\ media\ delle\ code\n}
    fprintf(fd file, "Centro &Classe1 &Classe2 &Classe3 &Totale
    fprintf(fd file, "\n cpu web server i-esimo: \t");
\quad \textbf{for} \; (\; j = 0 \, ; \;\; j < \hspace{-0.05cm} \text{NUM\_CLASSES} \, ; \;\; j + \hspace{-0.05cm} +)
{
         fprintf(fd_file, "&%.7f\t", qlen_cpu_web_server[j]/(
             NUM ITERATIONS));
         tot temp += qlen cpu web server[j]/(NUM ITERATIONS);
```

```
}
print_tot(fd_file);
fprintf(fd\_file, "\n disco i-esimo: \t");
\quad \textbf{for} \; (\; j = 0 \; ; \; \; j < \hspace{-0.05cm} \text{NUM\_CLASSES} \; ; \; \; j + \hspace{-0.05cm} + \hspace{-0.05cm} )
{
         fprintf(fd file, "&%.7f\t", qlen disk[j]/(
             NUM ITERATIONS));
         tot temp += qlen disk[j]/(NUM ITERATIONS);
print_tot(fd_file);
fprintf(fd_file, "\n inLink: \t");
for (j=0; j < NUM CLASSES; j++)
         fprintf(fd file, "&%.7f\t", qlen inLink[j]/(
             NUM ITERATIONS));
         tot\_temp += qlen\_inLink[j]/(NUM\_ITERATIONS);
}
print_tot(fd_file);
fprintf(fd file, "\n outLink: \t");
for (j=0; j \le NUM CLASSES; j++)
{
         fprintf(fd_file, "&%.7f\t", qlen_outLink[j]/(
             NUM ITERATIONS));
         tot_temp += qlen_outLink[j]/(NUM_ITERATIONS);
}
print tot(fd file);
fprintf(fd file, "\n cpu web switch: \t");
for (j=0; j \le NUM CLASSES; j++)
{
         fprintf(fd file, "&%.7f\t", qlen cpu web switch[j]/(
             NUM ITERATIONS));
         tot\_temp \ += \ qlen\_cpu\_web\_switch [\ j\ ] \ / \ (NUM\_ITERATIONS) \ ;
print_tot(fd_file);
fprintf(fd file, "\n LAN: \t");
for (j=0; j < NUM CLASSES; j++)
{
         fprintf(fd\_file, "&\%.7f\t", qlen\_L2[j]/(
             NUM ITERATIONS));
         tot_temp += qlen_L2[j]/(NUM_ITERATIONS);
print tot(fd file);
```

```
fprintf(fd file, "\n LS1: \t");
              for (j=0; j < NUM CLASSES; j++)
              {
                       fprintf(fd\_file, "&%.7f\t", qlen\_ls1[j]/(
                            NUM ITERATIONS));
                       tot temp += qlen ls1[j]/(NUM ITERATIONS);
              print tot(fd file);
              fprintf(fd file, "\n LS2: \t");
              \quad \textbf{for} \; (\; j = 0 \, ; \;\; j < \hspace{-0.05cm} \text{NUM\_CLASSES} \, ; \;\; j + \hspace{-0.05cm} +)
              {
                       fprintf(fd_file, "&%.7f\t", qlen_ls2[j]/(
                           NUM ITERATIONS));
                       tot temp += qlen ls2[j]/(NUM ITERATIONS);
              }
              print_tot(fd_file);
              fprintf(fd_file, "\n LW2: \t");
              for (j=0; j < NUM CLASSES; j++)
              {
                       fprintf(fd_file, "&%.7f\t", qlen_lw2[j]/(
                           NUM ITERATIONS));
    tot_temp += qlen_lw2[j]/(NUM_ITERATIONS);
print_tot(fd_file);
if(variant == LINK ADD)  {
                       fprintf(fd_file, "\n LINK_ADD: \t");
                       \quad \textbf{for} \; (\; j = 0; \;\; j < \text{NUM CLASSES}; \;\; j + +)
                       {
                                 fprintf(fd_file, "&%.7f\t", qlen_link_add[j]
                                     ]/(NUM ITERATIONS));
                                tot\_temp += qlen\_link\_add[j]/(NUM ITERATIONS
                                     );
                       print_tot(fd_file);
                       fprintf(fd file, "\n LW3: \t");
              for (j=0; j < NUM CLASSES; j++)
                       {
                                 fprintf(fd_file, "&%.7f\t", qlen_lw3[j]/(
                                     NUM_ITERATIONS));
                                tot_temp += qlen_lw3[j]/(NUM_ITERATIONS);
                       print tot(fd file);
```

```
}
             fprintf(fd file, "\n\n\n) Medio di Risposta\n\
                 hline\n");
             f\,p\,rin\,t\,f\,(\,f\,d\,\_file\,\,,\,\,\,\text{"Centro \&Classe1 \&Classe2 \&Classe3 \&Totale}
                 \\\\n\\hline\n\\hline");
             fprintf(fd file, "\n cpu web server i-esimo: \t");
             for (j=0; j \le NUM CLASSES; j++)
             {
                      fprintf(fd\_file\;,\;"\&\%.7f\t"\;,\;rtime\_cpu\_web\_server[j]
                          ]/(NUM ITERATIONS));
                      tot_temp += rtime_cpu_web_server[j]/(NUM_ITERATIONS)
             }
             print tot(fd file);
             fprintf(fd\_file, "\n disco i-esimo: \t");
             for (j=0; j < NUM CLASSES; j++)
             {
                      fprintf(fd_file, "&%.7f\t", rtime_disk[j]/(
                          NUM ITERATIONS));
    tot\_temp \ += \ rtime\_disk\left[\ j\ \right]/\left(NUM\_ITERATIONS\right);
}
print tot(fd file);
             fprintf(fd file, "\n inLink: \t");
             for (j=0; j \le NUM CLASSES; j++)
             {
                      fprintf(fd file, "&%.7f\t", rtime inLink[j]/(
                          NUM ITERATIONS));
                      tot temp += rtime inLink[j]/(NUM ITERATIONS);
             print_tot(fd_file);
             fprintf(fd file, "\n outlink: \t");
             for (j=0; j < NUM CLASSES; j++)
             {
                      fprintf(fd\_file, "&%.7f\t", rtime\_outLink[j]/(
                          NUM ITERATIONS));
                      tot temp += rtime outLink[j]/(NUM ITERATIONS);
             print tot(fd file);
             fprintf(fd\_file, "\n cpu web switch: \t");
             for (j=0; j < NUM CLASSES; j++)
             {
```

```
fprintf(fd file, "&%.7f\t", rtime cpu web switch[j
                                  ]/(NUM ITERATIONS));
                            tot temp += rtime cpu web switch [j] / (NUM ITERATIONS)
                 }
                 print_tot(fd_file);
                 fprintf(fd file, "\n LAN: \t");
                 for (j=0; j < NUM CLASSES; j++)
                 {
                             fprintf(fd file, "&%.7f\t", rtime L2[j]/(
                                 NUM ITERATIONS));
                            tot_temp += rtime_L2[j]/(NUM_ITERATIONS);
                 }
                 print tot(fd file);
                 fprintf(fd_file, "\n LS1: \t");
                 \quad \textbf{for} \; (\; j = 0 \; ; \; \; j < \text{NUM\_CLASSES} \; ; \; \; j + +)
                 {
                             fprintf(fd_file, "&%.7f\t", rtime_ls1[j]/(
                                  NUM_ITERATIONS));
     tot\_temp \ += \ rtime\_ls1[j]/(NUM\_ITERATIONS);
}
print tot(fd file);
fprintf(fd file, "\n LS2: \t");
                 \quad \textbf{for} \; (\; j = 0 \, ; \;\; j < \hspace{-0.05cm} \text{NUM\_CLASSES} \, ; \;\; j + \hspace{-0.05cm} + \hspace{-0.05cm} )
                             fprintf(fd file, "&%.7f\t", rtime ls2[j]/(
                                  NUM ITERATIONS));
     tot temp += rtime ls2[j]/(NUM ITERATIONS);
print_tot(fd_file);
fprintf(fd file, "\n LW2: \t");
                 \quad \textbf{for} \; (\; j = 0 \, ; \;\; j < \hspace{-0.05cm} \text{NUM\_CLASSES} \, ; \;\; j + \hspace{-0.05cm} +)
                 {
                             fprintf(fd\_file\;,\;"\&\%.7f\t"\;,\;rtime\_lw2\;[\;j\;]\,/(
                                  NUM ITERATIONS));
                            tot temp += rtime lw2[j]/(NUM ITERATIONS);
}
                 print tot(fd file);
if(variant == LINK\_ADD) {
                            fprintf(fd file, "\n LINK_ADD: \t");
                            \label{eq:formula} \textbf{for} \; (\; j = 0 \; ; \quad j < \hspace{-0.5em} \text{NUM\_CLASSES} \; ; \quad j + \hspace{-0.5em} + \hspace{-0.5em} )
```

```
fprintf(fd file, "&%.7f\t", rtime link add[j
                                        ]/(NUM ITERATIONS));
                                   tot temp += rtime link add[j]/(
                                        NUM ITERATIONS);
                          }
                          print tot(fd file);
                          fprintf(fd file, "\n LW3: \t");
                          for (j=0; j<NUM CLASSES; j++)
                           {
                                    fprintf(fd file, "&%.7f\t", rtime lw3[j]/(
                                        NUM ITERATIONS));
        tot_temp += rtime_lw3[j]/(NUM_ITERATIONS);
      print_tot(fd_file);
                 fprintf(fd file, "\n\n Tasso medio di arrivi (lambda)
                                               : %g\n", lambda_tmp/(
                      NUM ITERATIONS));
                 fclose (fd file);
        }
}
//trovare un modo elegante di passare la variante, per ora passo RANDOM
//Simulazione dell'intero modello.
void sim(int argc, char **argv) {
         p rintf("Starting simulation...\n");
        \quad \textbf{int} \quad i=0\,;
        int client_id;
        int variante = LEAST LOADED;
        int reset;
        char filename[25];
        FILE *output;
        \mathbf{for} (i = 0; i < \text{NUM ITERATIONS}; i++)  {
                 \verb"num_osservazion" i = 0;
                 reset = 0;
                 \mathtt{create} \, (\, \texttt{"simulation"} \,) \; ;
                 max processes (MAX PROCESSES);
                 max facilities(MAX FACILITIES);
                 max servers (MAX SERVERS);
                 max classes (MAX CLASSES);
                 filename[0] = '\0';
                  sprintf(filename, "Sim_prova_%d", i);
                 output = fopen(filename, "w");
                  set _ output _ file (output );
```

```
// Inizializzazione degli stream (reseed simtime*i+num)
            sess\_req\_1 = create\_stream();
            reseed (sess req 1, (int) simtime ()+i+1);
            sess\_req\_2 = create\_stream();
            \verb|reseed (sess_req_2|, | (\verb|int|) simtime () *2 + i + 1);
            user_tt = create_stream();
            reseed (user tt, (int) simtime()*3+i+1);
            object req = create stream();
            reseed (object req, (int) simtime ()*4+i+1);
            html 1 = create stream();
            reseed (html 1, (int) simtime()*5+i+1);
            html_2 = create_stream();
            reseed (html_2, (int) simtime()*6+i+1);
            obj size = create stream();
            reseed (obj size, (int) simtime()*7+i+1);
            p hit proxy = create stream();
            reseed (p hit proxy, (int) simtime()*8+i+1);
            // Inizializzazione delle facility
            inLink = facility("inLink");
            outLink = facility ("outLink");
            LS1 = facility("LS1");
            LS2 = facility("LS2");
            CPU web switch = facility("CPU_web_switch");
            L2 = facility("L2");
            facility_set(cpuWS, "cpuWS", NUM_SERVER);
            facility set(diskWS, "diskWS", NUM SERVER*NUM DISK);
            facility_set(LW2, "LW2", NUM SERVER);
if(variante == LINK ADD) {
             link add = facility("link_add");
             facility set (LW3, "LW3", NUM SERVER);
            }
            // Table initialization
            rtime = table("System Response Time");
            resptime = permanent\_table("Tempo di risposta del sistema");\\
            char className[20];
            className[0] = '\0';
            WebServer = box("Web Server");
            WebSwitch = box("Web Switch");
            lambda = meter("Arrival Rate");
            int j=0;
            for (; j < NUM CLASSES; j++){
```

```
sprintf(className, "Classe%d", j);
                          request Classes [j] = process class (className);
                 }
                 collect class facility all();
                 reseed (sess req 1, (int) simtime ()+i+1);
                 reseed (sess req 2, (int) simtime ()*2+i+1);
                 reseed (user\_tt , (int) simtime()*3+i+1);
                 reseed(object\_req, (int)simtime()*4+i+1);
                 \verb|reseed| (| \verb|html_1|, | (| \verb|int|) | simtime (|) *5 + | i+1);
                 reseed(html_2, (int)simtime()*6+i+1);
                 reseed (obj size, (int) simtime()*7+i+1);
                 reseed(p hit proxy, (int)simtime()*8+i+1);
                 while (state (converged) == NOT_OCC && num_osservazioni < 500000)
                          hold (exponential (1/(double)ARRIVAL));
                          printf("num_osservazioni %d\n", num_osservazioni);
                          web session (client id, variante, 0, -1);
                          client id++;
                          if(num osservazioni>100000 &&(!reset)) {
                                   printf("Reset statistics %g\n", simtime());
                                   reset();
                                   reset=1;
                                   table_confidence(rtime);
                                  table\_run\_length (rtime, 0.005, 0.98,
                                       10000.0);
                          }
                 printf("Fine generazione a %g - iterazione %d\n", simtime(),
                      i);
                 report facilities ();
                 report _table(rtime);
                 report _ boxes();
                 meter summary();
                 tabulate(resptime, table mean(rtime));
                 statistics (i, variante);
                 rerun();
                 printf("End %i\n", i);
        table_summary();
}
```

 $className[0] = '\0';$

6.8 analytical.c

```
\#include < stdio.h>
#include < stdlib.h>
\#include < sys/types.h>
\#include < sys/stat.h>
\#include < time.h>
#include < string.h>
\#include < stdarg.h>
#include "common.h"
#include "service.h"
#define LAMBDA_SIM 3308.79 //prova
\#define NUM OBS 10000000
// Calcola la lunghezza della coda
double calc queue length (double utilization)
        return utilization / (1 - utilization);
}
// Calcola il tempo di risposta
double calc_response_time(double service, double utilization)
{
        return service /(1 - utilization);
}
//Calcola e salva su un file gli indici di prestazione del sistema
int main(int argc, char **argv)
{
        FILE *fd file;
        char *pathname = (char*) malloc(128);
         sprintf(pathname, "risultati modello analitico.txt");
        fd file = fopen (pathname, "w");
        \mathbf{double} \ \ \mathbf{utilizzazione\_L2} \ [ \mathbf{NUM\_CLASSES} ] \ , \ \ \mathbf{utilizzazione\_inLink} \ [
            NUM_CLASSES], utilizzazione_outLink[NUM_CLASSES],
        utilizzazione_cpu_web_switch[NUM_CLASSES],
             utilizzazione cpu web server[NUM CLASSES],
             utilizzazione disco web server[NUM CLASSES],
             utilizzazione link add [NUM CLASSES], utilizzazione ls1 [
             NUM CLASSES], utilizzazione ls2 [NUM CLASSES], utilizzazione lw2 [
             NUM CLASSES], utilizzazione lw3 [NUM CLASSES];
        double coda_L2, coda_inLink, coda_outLink, coda_cpu_web_switch,
             coda cpu web server, coda disco web server, coda link add,
             coda ls1, coda ls2, coda lw2, coda lw3;
```

```
double tr L2, tr inLink, tr outLink, tr cpu web switch,
          tr cpu web server, tr disco web server, tr link add, tr ls1,
          tr ls2, tr lw2, tr lw3;
      //centroidi
      double doc size[NUM CLASSES];
      /*doc \ size[0] = 10281; \ DOC \ SIZE \ PER \ K=3
      doc \ size[1] = 279513744;
      doc_size[2] = 715827882;
      */
      doc size[0] = 10073;
      doc\_size[1] = 17740962;
      doc_size[2] = 70926601;
      doc size[3] = 279513744;
      doc size[4] = 715827882;
      //probabilita 'che la risorsa non si trovi nel proxy
      double miss = 1-P HIT;
      int i = 0;
      //tasso\ di\ richieste\ per\ ogni\ classe\ =\ probabilita' di\ classe *
           tasso di richieste totale
double lambda[NUM CLASSES];
      /*lambda[0] = ((double)9999995/(double)NUM OBS)*LAMBDA SIM;
      lambda[1] = ((double)4/(double)NUM OBS)*LAMBDA SIM;
      lambda[2] = ((double)1/(double)NUM OBS)*LAMBDA SIM;
      lambda[0] = ((double) 9999917/(double)NUM OBS)*LAMBDA SIM;
      lambda[1] = ((double) 65/(double)NUM_OBS)*LAMBDA_SIM;
      lambda[2] = ((double)13/(double)NUM OBS)*LAMBDA SIM;
      lambda[3] = ((double) 4/(double) NUM OBS) *LAMBDA SIM;
      lambda[4] = ((double)1/(double)NUM OBS)*LAMBDA SIM;
      fprintf(fd file, "calcolo indici locali variante standard\n");
      //calcolo utilizzazioni
      \label{eq:for_state} \textbf{for} \; (\; i = 0 \; ; \quad i \; < \; \text{NUM CLASSES} \; ; \quad i + +) \; \; \{
               fprintf\left(fd\_file\;,\;\; \texttt{"\nutilizzazioni classe \%d\n"}\;,i\;\right);
               utilizzazione L2[i] = lambda[i]*(D LAN(doc size[i])+D LAN(0)
                    );
               fprintf(fd file, "L2: %9.9f\n", utilizzazione L2[i]);
               utilizzazione_inLink[i] = lambda[i]*D_InLink();
               fprintf(fd file, "inLink: %9.9f\n", utilizzazione inLink[i])
                   ;
```

```
utilizzazione outLink[i] = lambda[i]*D OutLink(doc size[i]);
         fprintf(fd\_file\;,\; \verb"outLink: ~\%9.9f\n"\;,\; utilizzazione\_outLink[i]
              ]);
         utilizzazione cpu web switch[i] = lambda[i] * D Cpu(
             CPU WEB SWITCH SERVICE RATE) * 2; //fattore due perche'
              processa sia richieste in entrata che in uscita (two-way
         fprintf (fd file, "cpu web switch: %9.9f\n",
              utilizzazione cpu web switch[i]);
         utilizzazione\_cpu\_web\_server[i] \ = \ (lambda[i] \ * \ D\_Cpu(
             CPU_SERVICE_RATE) * 2)/(double) NUM_SERVER;
         fprintf(fd file, "cpu web server: %9.9f\n",
              utilizzazione cpu web server[i]);
         utilizzazione disco web server[i] = (lambda[i] * D WSDisk(
              doc size[i]))/(NUM SERVER*NUM DISK);
         fprintf(fd file, "disco web server: %9.9f\n",
              utilizzazione_disco_web_server[i]);
         utilizzazione ls1[i] = lambda[i]*(D LS1in()+D LS1out(
              doc size[i]));
         fprintf(fd file, "LS1: %9.9f\n", utilizzazione ls1[i]);
         utilizzazione\_ls2\left[\:i\:\right]\:=\:lambda\left[\:i\:\right]*\left(D\_LAN(\:doc\_size\left[\:i\:\right]\right)+D\_LAN
              (0));
         fprintf(fd file, "LS2: %9.9f\n", utilizzazione ls2[i]);
         utilizzazione\_lw2[i] = (lambda[i]*(D\_LAN(doc\_size[i])+D\_LAN
              (0)))/((\mathbf{double})NUM SERVER);
         fprintf(fd file, "LW2: %9.9f\n", utilizzazione lw2[i]);
}
//calcolo lunghezza code
\label{eq:for} \textbf{for} \hspace{0.1cm} (\hspace{1mm} i = 0 \hspace{1mm} ; \hspace{1mm} i \hspace{1mm} < \hspace{1mm} \text{NUM CLASSES} \hspace{1mm} ; \hspace{1mm} i + +) \hspace{1mm} \{
         coda\_L2 \ = \ calc\_queue\_length \left( \ utilizzazione\_L2 \ [ \ i \ ] \right);
         fprintf(fd_file, "L2: %9.9f\n", coda_L2);
         coda inLink = calc queue length(utilizzazione inLink[i]);
         fprintf(fd file, "inLink: %9.9f\n", coda inLink);
         coda outLink = calc queue length(utilizzazione outLink[i]);
         fprintf(fd file, "outLink: %9.9f\n", coda outLink);
         coda cpu web switch = calc queue length (
              utilizzazione\_cpu\_web\_switch[i]);\\
```

```
fprintf(fd file, "cpu web switch: %9.9f\n",
            coda cpu web switch);
        coda_cpu_web_server = calc_queue_length(
            utilizzazione_cpu_web_server[i]);
        fprintf(fd_file, "cpu web server: %9.9f\n",
            coda cpu web server);
        coda disco web server = calc queue length (
            utilizzazione_disco_web_server[i]);
        fprintf(fd file, "disco web server: %9.9f\n",
            coda_disco_web_server);
        coda ls1 = calc queue length(utilizzazione ls1[i]);
        fprintf(fd file, "LS1: %9.9f\n", coda ls1);
        coda\_ls2\ =\ calc\_queue\_length\left(\ utilizzazione\_ls2\ [\ i\ ]\right)\ ;
        fprintf(fd file, "LS2: %9.9f\n", coda ls2);
        coda_lw2 = calc_queue_length(utilizzazione_lw2[i]);
        fprintf(fd file, "LW2: %9.9f\n", coda lw2);
}
//tempi di residenza
\mathbf{for} (i=0; i < \text{NUM CLASSES}; i++)  {
        fprintf(fd file, "\ntempi di residenza %d\n", i);
        tr_L2 = calc_response_time(D_LAN(doc_size[i]),
            utilizzazione_L2[i]);
        fprintf(fd file, "L2: %9.9f\n", tr L2);
        tr inLink = calc response time(D InLink(),
            utilizzazione inLink[i]);
        fprintf(fd_file, "inLink: %9.9f\n", tr_inLink);
        tr\_outLink = calc\_response\_time(D\_OutLink(doc\_size[i]),
            utilizzazione outLink[i]);
        fprintf(fd_file, "outLink: %9.9f\n", tr_outLink);
        tr cpu web switch = calc response time(D Cpu(
            CPU WEB SWITCH SERVICE RATE) * 2,
            utilizzazione cpu web switch[i]);
        fprintf(fd file, "cpu web switch: %9.9f\n",
            tr_cpu_web_switch);
        tr cpu web server = calc response time(D Cpu(
            CPU_SERVICE_RATE) * 2, utilizzazione_cpu_web_server[i]);
```

```
fprintf(fd file, "cpu web server: %9.9f\n",
             tr cpu web server);
         tr\_disco\_web\_server = calc\_response\_time(D\_WSDisk(doc\_size[i
             ]), utilizzazione_disco_web_server[i]);
         fprintf(fd_file, "disco web server: %9.9f\n",
             tr disco web server);
         tr ls1 = calc response time((D LS1in()+D LS1out(doc size[i])
             ), utilizzazione ls1[i]);
         fprintf(fd file, "LS1: %9.9f\n", tr ls1);
         tr_ls2 = calc_response_time(D_LAN(doc_size[i]),
             utilizzazione ls2[i]);
         fprintf(fd file, "LS2: %9.9f\n", tr ls2);
         tr lw2 = calc response time(D LAN(doc size[i]),
             utilizzazione_lw2[i]);
         fprintf(fd file, "LS2: %9.9f\n", tr lw2);
}
//nel caso di inserimento del proxy bisogna moltiplicare tutte le
     utilizzazioni per 0.6, nel caso di link addizionale bisogna
     ricalcolare l'utilizzazione della cpu del web switch (one way)
    e calcolare la nuova utilizzazione della L3.
fprintf(fd\_file\;,\; \verb"\ncalcolo" indici locali con link addizionale \verb"\n"");
//calcolo utilizzazioni link addizionale, cosa cambia nella LAN L2?
\quad \textbf{for} \; (\; i=0 \; ; \quad i \; < \; \text{NUM CLASSES} \; ; \quad i++) \; \; \{ \;
         fprintf(fd_file, "\nutilizzazioni classe %d\n",i);
         u\,t\,ili\,z\,z\,a\,z\,i\,o\,n\,e\quad L\,2\,\left[\,\,i\,\,\right]\,\,=\,\,l\,a\,m\,b\,d\,a\,\left[\,\,i\,\,\right]*D\_LAN\left(\,0\,\,\right)\,;
         fprintf(fd file, "L2: %9.9f\n", utilizzazione L2[i]);
         utilizzazione inLink[i] = lambda[i]*D InLink();
         fprintf(fd file, "inLink: %9.9f\n", utilizzazione inLink[i])
         utilizzazione\_cpu\_web\_switch[i] = lambda[i] * D\_Cpu(
             CPU WEB SWITCH SERVICE RATE); //fattore due perche'
             processa sia richieste in entrata che in uscita (two-way
             )
         fprintf(fd file, "cpu web switch: %9.9f\n",
             utilizzazione\_cpu\_web\_switch[i]);
         utilizzazione cpu web server[i] = (lambda[i] * D Cpu(
             CPU SERVICE RATE) * 2)/(double) NUM SERVER;
```

```
fprintf(fd file, "cpu web server: %9.9f\n",
            utilizzazione cpu web server[i]);
        utilizzazione disco web server[i] = (lambda[i] * D WSDisk(
            doc size[i]))/(NUM SERVER*NUM DISK);
        fprintf(fd file, "disco web server: %9.9f\n",
            utilizzazione disco web server[i]);
        utilizzazione link add[i] = lambda[i]*D linkAdd(doc size[i])
        fprintf(fd file, "linkAdd: %9.9f\n", utilizzazione link add[
            i]);
        utilizzazione ls1[i] = lambda[i]*(D LS1in());
        fprintf(fd file, "LS1: %9.9f\n", utilizzazione ls1[i]);
        utilizzazione_ls2[i] = lambda[i]*D LAN(0);
        fprintf(fd file, "LS2: %9.9f\n", utilizzazione ls2[i]);
        utilizzazione_lw2[i] = (lambda[i]*D_LAN(0))/((double)
            NUM SERVER);
        fprintf(fd file, "LW2: %9.9f\n", utilizzazione lw2[i]);
        utilizzazione lw3[i] = (lambda[i]*D linkAdd(doc size[i]))/(
            double) NUM SERVER;
        fprintf(fd file, "LW3: %9.9f\n", utilizzazione lw3[i]);
//calcolo lunghezza code
\quad \textbf{for} \; (\; i=0 \; ; \quad i \; < \; \text{NUM CLASSES} \; ; \quad i++) \; \; \{ \;
        fprintf(fd\_file, "\nlunghezze code classe %d\n",i);
        coda L2 = calc queue length(utilizzazione L2[i]);
        fprintf(fd file, "L2: %9.9f\n", coda L2);
        coda inLink = calc queue length(utilizzazione inLink[i]);
        fprintf(fd file, "inLink: %9.9f\n", coda inLink);
        coda cpu web switch = calc queue length (
            utilizzazione\_cpu\_web\_switch[i]);\\
        fprintf(fd file, "cpu web switch: %9.9f\n",
            coda cpu web switch);
        coda cpu web server = calc queue length(
            utilizzazione_cpu_web_server[i]);
        fprintf(fd\_file, "cpu web server: %9.9f\n",
            coda cpu web server);
```

```
coda disco web server = calc queue length (
            utilizzazione_disco_web_server[i]);
        fprintf(fd file, "disco web server: %9.9f\n",
            coda_disco_web_server);
        coda link add = calc queue length(utilizzazione link add[i])
        fprintf(fd file, "linkAdd: %9.9f\n", coda link add);
        coda_ls1 = calc_queue_length(utilizzazione_ls1[i]);
        fprintf(fd file, "LS1: %9.9f\n", coda ls1);
        coda_ls2 = calc_queue_length(utilizzazione_ls2[i]);
        fprintf(fd file, "LS2: %9.9f\n", coda ls2);
        coda lw2 = calc queue length(utilizzazione lw2[i]);
        fprintf(fd file, "LW2: %9.9f\n", coda lw2);
        coda lw3 = calc queue length(utilizzazione lw3[i]);
        fprintf(fd_file, "LW3: %9.9f\n", coda_lw3);
}
//tempi di residenza
\mathbf{for} (i=0; i < \text{NUM CLASSES}; i++)  {
        fprintf(fd file, "\ntempi di residenza %d\n", i);
        tr_L2 = calc_response_time(D_LAN(0), utilizzazione_L2[i]);
        fprintf(fd_file, "L2: %9.9f\n", tr_L2);
        tr_inLink = calc_response_time(D_InLink())
            utilizzazione_inLink[i]);
        fprintf(fd file, "inLink: %9.9f\n", tr inLink);
        tr cpu web switch = calc response time(D Cpu(
            CPU WEB SWITCH SERVICE RATE) * 2,
            utilizzazione\_cpu\_web\_switch[i]);\\
        fprintf(fd_file, "cpu web switch: %9.9f\n",
            tr_cpu_web_switch);
        tr cpu web server = calc response time(D Cpu(
            CPU SERVICE RATE) * 2, utilizzazione cpu web server[i]);
        fprintf(fd file, "cpu web server: %9.9f\n",
            tr_cpu_web_server);
        tr disco web server = calc response time(D WSDisk(doc size[i
            ]), utilizzazione_disco_web_server[i]);
```

```
fprintf(fd file, "disco web server: %9.9f\n",
              tr disco web server);
         tr\_link\_add \, = \, calc\_response\_time \, (\, D\_linkAdd \, (\, doc\_size \, [\, i \, ]\,) \,\, ,
              utilizzazione_link_add[i]);
         fprintf(fd file, "linkAdd: %9.9f\n", tr link add);
         tr ls1 = calc response time(D LS1in(), utilizzazione ls1[i])
         fprintf(fd file, "LS1: %9.9f\n", tr ls1);
         tr\_ls2 \ = \ calc\_response\_time(D\_LAN(0) \ , \ utilizzazione\_ls2 \ [i]) \ ;
         fprintf(fd_file, "LS2: %9.9f\n", tr_ls2);
         tr lw2 = calc response time(D LAN(0), utilizzazione lw2[i]);
         fprintf(fd file, "LW2: %9.9f\n", tr lw2);
         tr_lw3 = calc_response_time(D_linkAdd(doc_size[i]),
              utilizzazione lw3[i]);
         fprintf(fd_file, "LW3: %9.9f\n", tr_lw3);
}
fprintf(fd file, "\ncalcolo indici locali con proxy\n");
\label{eq:for} \textbf{for} \; (\; i=0 \; ; \quad i \; < \; \text{NUM CLASSES} \; ; \quad i++) \; \; \{
         fprintf(fd file, "\nutilizzazioni classe %d\n",i);
         utilizzazione\_L2\left[\:i\:\right] \:=\: miss*lambda\left[\:i\:\right]*\left(D\_LAN(\:doc\_size\left[\:i\:\right]\right) +
         fprintf(fd file, "L2: %9.9f\n", utilizzazione L2[i]);
         utilizzazione inLink[i] = miss*lambda[i]*D InLink();
         fprintf(fd file, "inLink: %9.9f\n", utilizzazione inLink[i])
         utilizzazione outLink[i] = miss*lambda[i]*D OutLink(doc size
         fprintf(fd file, "outLink: %9.9f\n", utilizzazione outLink[i
             1);
         utilizzazione cpu web switch[i] = miss*lambda[i] * D Cpu(
             CPU WEB SWITCH SERVICE RATE)* 2; //fattore due perche;
              processa sia richieste in entrata che in uscita (two-way
         fprintf(fd file, "cpu web switch: %9.9f\n",
              utilizzazione\_cpu\_web\_switch[i]);\\
```

```
utilizzazione cpu web server[i] = miss*(lambda[i] * D Cpu(
             CPU SERVICE RATE) * 2)/(double) NUM SERVER;
         fprintf(fd file, "cpu web server: %9.9f\n",
              utilizzazione cpu web server[i]);
         utilizzazione disco web server[i] = miss*(lambda[i] *
              D WSDisk(doc size[i]))/(NUM SERVER*NUM DISK);
         fprintf(fd file, "disco web server: %9.9f\n",
              utilizzazione disco web server[i]);
         utilizzazione ls1[i] = miss*lambda[i]*(D LS1in()+D LS1out(
              doc size[i]));
         fprintf(fd file, "LS1: %9.9f\n", utilizzazione_ls1[i]);
         utilizzazione\_ls2\left[\:i\:\right] \;=\; miss*lambda\left[\:i\:\right]*\left(D\_LAN\left(\:doc\_size\left[\:i\:\right]\right) + \right.
             D LAN(0);
         fprintf(fd file, "LS2: %9.9f\n", utilizzazione ls2[i]);
         utilizzazione lw2[i] = miss*(lambda[i]*(D LAN(doc size[i])+
             D LAN(0)) / ((double) NUM SERVER);
         fprintf(fd file, "LW2: %9.9f\n", utilizzazione lw2[i]);
//calcolo lunghezza code
\label{eq:for} \textbf{for} \hspace{0.1cm} (\hspace{1mm} i = 0 \hspace{1mm} ; \hspace{1mm} i \hspace{1mm} < \hspace{1mm} \text{NUM CLASSES} \hspace{1mm} ; \hspace{1mm} i + +) \hspace{1mm} \{
         fprintf(fd file, "\nlunghezze code classe %d\n",i);
         coda L2 = calc queue length(utilizzazione L2[i]);
         fprintf(fd file, "L2: %9.9f\n", coda L2);
         coda_inLink = calc_queue_length(utilizzazione_inLink[i]);
         fprintf(fd_file, "inLink: %9.9f\n", coda_inLink);
         coda_outLink = calc_queue_length(utilizzazione_outLink[i]);
         fprintf(fd file, "outLink: %9.9f\n", coda outLink);
         coda cpu web switch = calc queue length(
              utilizzazione cpu web switch[i]);
         fprintf(fd file, "cpu web switch: %9.9f\n",
              coda cpu web switch);
         coda_cpu_web_server = calc_queue_length(
              utilizzazione cpu web server[i]);
         fprintf(fd file, "cpu web server: %9.9f\n",
              coda cpu web server);
         coda\_disco\_web\_server = calc\_queue\_length(
              utilizzazione_disco_web_server[i]);
         fprintf(fd file, "disco web server: %9.9f\n",
              coda_disco_web_server);
```

```
coda ls1 = calc queue length(utilizzazione ls1[i]);
         fprintf(fd file, "LS1: %9.9f\n", coda ls1);
         coda_ls2 = calc_queue_length(utilizzazione_ls2[i]);
         fprintf(fd file, "LS2: %9.9f\n", coda ls2);
         coda\_lw2\ =\ calc\_queue\_length\left(\,utiliz\,z\,a\,z\,ion\,e\_l\,w\,2\,\left[\,\,i\,\,\right]\,\right)\,;
         fprintf(fd file, "LW2: %9.9f\n", coda lw2);
}
//tempi di residenza
\quad \textbf{for} \; (\; i=0 \; ; \quad i \; < \; \text{NUM CLASSES} \; ; \quad i++) \; \; \{ \;
         fprintf(fd\_file, "\ntempi di residenza %d\n", i);
        tr \ L2 = calc \ response\_time(D\_LAN(doc\_size[i]) \ ,
             utilizzazione L2[i]);
         fprintf(fd file, "L2: %9.9f\n", tr L2);
         tr_inLink = calc_response_time(D_InLink(),
             utilizzazione inLink[i]);
         fprintf(fd_file, "inLink: %9.9f\n", tr_inLink);
         tr outLink = calc response time(D OutLink(doc size[i]),
             utilizzazione_outLink[i]);
         fprintf(fd file, "outLink: %9.9f\n", tr outLink);
         tr cpu web switch = calc response time(D Cpu(
             CPU WEB SWITCH SERVICE RATE) * 2,
             utilizzazione_cpu_web_switch[i]);
         fprintf(fd file, "cpu web switch: %9.9f\n",
             tr_cpu_web_switch);
         tr cpu web server = calc response time(D Cpu(
             CPU_SERVICE_RATE) * 2, utilizzazione_cpu_web_server[i]);
         fprintf(fd file, "cpu web server: %9.9f\n",
             tr cpu web server);
         tr_disco_web_server = calc_response_time(D_WSDisk(doc_size[i
             ]), utilizzazione_disco_web_server[i]);
         fprintf(fd file, "disco web server: %9.9f\n",
             tr disco web server);
         tr ls1 = calc response time((D LS1in()+D LS1out(doc size[i])
             ), utilizzazione ls1[i]);
         fprintf(fd_file, "LS1: %9.9f\n", tr_ls1);
         tr\_ls2 \ = \ calc\_response\_time(D\_LAN(doc\_size[i]) \ ,
             utilizzazione ls2[i]);
```

Listings

common.h																	50
cluster.c																	52
gaussiana_i	nve	ersa	a.c														57
service.c																	60
client.c																	63
transient.c																	68
main.c																	74
analytical.c																	88

Elenco delle tabelle

1.1	specifiche	5
2.1	Risultati clustering	10
2.2	specifiche2	11
3.1	specifiche3	17
3.2	specifiche4	20
3.3	Utilizzazioni	30
3.4	Lunghezza code	30
3.5	Tempo medio di risposta	31
3.6	Utilizzazioni	32
3.7	Lunghezza Code	32
3.8	Tempo medio di risposta	33
3.9	Utilizzazioni	34
3.10	Lunghezza Code	34
3.11	Tempo medio di risposta	35
3.12	Utilizzazioni	36
3.13	Lunghezza Code	36
3.14	Tempo medio di risposta	37
3.15	Utilizzazioni	37
		38
		39
4.1	Risultati clustering	40

ELENCO DELLE TABELLE

4.2	specifiche2	41
4.3	Utilizzazioni	42
4.4	Lunghezza Code	43
4.5	Tempo di residenza	43
4.6	Utilizzazioni	44
4.7	Lunghezza Code	45
4.8	Tempo di residenza	45
4.9	Utilizzazioni	46
4.10	Lunghezza Code	47
4.11	Tempo di residenza	47

Elenco delle figure

1.1	Schema																														4
1.2	Schema		٠		٠			•		•		•	•	•	•	•	•	•	•	•			•				٠		٠	•	6
2.1	Schema																														8
2.2	Schema						•	•			•													•	•			•		•	9
3.1	Carico .		•		•			•																			•		•		14
3.2	Carico .			•																											22
3.3	Grafico1								•												•	•				•					23
3.4	Grafico2																														23
3.5	Grafico3																														24
3.6	webclient																														26
3.7	webclient	2																													26

Indice analitico

algoritmo di Michael/Shucany/Haas, Overhead, 17

14

analitico, 3

AVG_SIZE_HTTP_REQ, 17

bandwidth, 17

burstiness, 8

business, 7

 $caratterizzazione\ funzionale,\ 7$

 $doc_size, 18$

docSize = 0, 18

for, 29

FRAMEOV, 17

heavy-tailed, 10

IPOV, 17

modello di workload, 7

MSS, 17

Ndatagrams, 17

NetworkTime, 17

next event time advance, 12

number of blocks, 18

orientato alle risorse, 7

Pareto, 10

Power-Law, 10

process-oriented, 12

rerun(), 29

rete di code, 3

simulation engine, 12

simulativo, 3

TCPOV, 17

workload, 7